# Жизненный цикл игры в Steam

имитация, сравнение моделей, прогноз по первым неделям

Документ для подготовки к защите

Курс «Имитационное и статистическое моделирование» · Михаил Петраченко · ноябрь 2026

**Как устроен документ.** Разделы идут в том порядке, в каком делалась работа. Теория стоит там, где понятие впервые понадобилось, в синих рамках «Теория N»; их список с номерами страниц в оглавлении теории ниже. Каждый график приложения стоит в разделе того шага, к которому он относится, и под ним серая рамка «Как читать». Жёлтые рамки отмечают места, о которых могут спросить. Числа взяты из `JOURNAL.md` и файлов `results/*.txt`.

**Приложение** запускается командой `streamlit run app.py` из папки проекта; номера экранов в подписях к рисункам совпадают с номерами в боковом меню.

# Оглавление


1 Вопрос и данные ..... 5
1.1 С чего начали ..... 5
1.2 Наборы данных ..... 5
1.3 Как из отзывов получился ряд ..... 5
2 Три простые кривые ..... 7
2.1 Что называется моделью ..... 7
2.2 Результат ..... 8
3 Как сравнивать модели: имитация и CRPS ..... 9
3.1 Решение: главная проверка — имитация ..... 9
4 Хокс: модель с памятью ..... 11
4.1 Результат и первая трещина ..... 11
4.2 Ограничение силы эха ..... 11
5 Толчки и итог первого блока ..... 12
5.1 Результат ..... 12
6 Типы траекторий ..... 14
7 Прогноз на отложенных неделях ..... 16
7.1 Постановка ..... 16
7.2 Результат: кривые уходят в ноль ..... 16
8 Плато ..... 18
8.1 Три способа задать плато ..... 18
8.2 Результат ..... 18
9 Шесть недорогих улучшений и финальная модель ..... 19
9.1 Улучшения калибровки ..... 19
9.2 Улучшения точности ..... 20
9.3 Финальная модель (решение автора) ..... 21
10 Проверка «отзывы вместо игроков» (M1) ..... 23
10.1 Результат ..... 23
11 Те же модели на числе игроков (M2) ..... 25
12 Восстановление параметров имитацией ..... 26
12.1 Зачем ..... 26
13 Устойчивость выводов ..... 28
14 Толчки внутри прогноза ..... 29
14.1 Вопрос ..... 29
15 Внешняя проверка на najzeko ..... 31
15.1 Постановка ..... 31
15.2 Результат ..... 31
16 Параметры как факты об играх ..... 33
16.1 Вопрос ..... 33
16.2 Результат ..... 33
17 Итог ..... 35
17.1 Что мы утверждаем ..... 35
17.2 Где слабо (сказать самому) ..... 35
17.3 Вопросы, которые могут задать ..... 35

# Указатель теории

Теория 1 Временной ряд счётчиков и цензурирование ..... 5
Теория 2 Отрицательное биномиальное распределение (NB) ..... 7
Теория 3 Метод максимального правдоподобия ..... 7
Теория 4 AIC и BIC ..... 8
Теория 5 Автокорреляция остатков ..... 8
Теория 6 Свободная имитация (метод Монте-Карло) ..... 9
Теория 7 Коридор 90% и покрытие ..... 9
Теория 8 CRPS — непрерывная ранжированная вероятностная оценка ..... 9
Теория 9 Процесс Хокса (самовозбуждающийся процесс) ..... 11
Теория 10 Модель с толчками и скрытые переменные ..... 12
Теория 11 Кластеризация: k-means и метод Уорда ..... 14
Теория 12 Как проверить, что кластеры не выдуманы ..... 14
Теория 13 Утечка и честная проверка предсказуемости ..... 14
Теория 14 Обучающая и проверочная части, фолды ..... 16
Теория 15 Простые планки (базовые прогнозы) ..... 16
Теория 16 Горизонты, CRPS суммы и бутстреп парных разностей ..... 16
Теория 17 Сжатие (штрафованное правдоподобие) ..... 18
Теория 18 Идентифицируемость ..... 18
Теория 19 Общий разброс из популяции ..... 19
Теория 20 Конформная калибровка ..... 19
Теория 21 Приближение Лапласа (неопределённость параметров) ..... 19
Теория 22 Регрессия плато ..... 20
Теория 23 Шаблон по ближайшим соседям ..... 20
Теория 24 Смесь предиктивных распределений ..... 20
Теория 25 Корреляции уровней и изменений ..... 23
Теория 26 Контроль на перестановках и заранее зафиксированный критерий ..... 23
Теория 27 Эксперимент по восстановлению параметров ..... 26
Теория 28 Анализ чувствительности ..... 28
Теория 29 Толчки как популяционная величина ..... 29
Теория 30 Биномиальное прореживание ..... 31
Теория 31 Медиана с бутстреп-интервалом, ранговая корреляция, стандартизованные коэффициенты ..... 33

# Список графиков

Рис. 1 Экран 1. Куда делись игры: отбор . . . . . 6
Рис. 2 Экран 1. Типичная форма: доля отзывов по неделям . . . . . 6
Рис. 3 Экран 2. Модель как генератор: имитации степенного закона и Хокса для Far Cry 5 . . . . . 10
Рис. 4 Экран 3. Единой лучшей модели нет: средний CRPS по четырём характеристикам . . . . . 12
Рис. 5 Экран 4. Насколько тип будущего предсказуем по первым 12 неделям . . . . . 15
Рис. 6 Экран 5. Прогноз всей кривой по первым 12 неделям для Far Cry 5 . . . . . 17
Рис. 7 Экран 7. Средний CRPS финальной модели и конкурентов по горизонтам, $L = 12$ . . . . . 21
Рис. 8 Экран 7. Покрытие 90%-коридора, $L = 12$ . . . . . 22
Рис. 9 Экран 8. Корреляция недельных изменений отзывов и онлайна, 338 игр . . . . . 23
Рис. 10 Экран 8. Пример: отзывы и онлайн одной игры на общих неделях . . . . . 24
Рис. 11 Экран 8. CRPS суммы за окно прогноза на онлайне . . . . . 25
Рис. 12 Экран 6. Ошибка оценки плато $\log\left(\frac{\hat{C}}{C}\right)$ на искусственных играх, $L = 12$ . . . . . 26
Рис. 13 Экран 6. Ошибка прогноза суммы за недели 12–103 на искусственных играх . . . . . 27
Рис. 14 Экран 6. Реальное плато против стартового объёма $S$, $L = 12$ . . . . . 27
Рис. 15 Экран 9. Средний CRPS моделей с толчками и без, $L = 12$ . . . . . 29
Рис. 16 Экран 9. Покрытие 90%-коридора моделей с толчками и без . . . . . 30
Рис. 17 Экран 10. Средний CRPS на внешнем наборе, $L = 12$ . . . . . 31
Рис. 18 Экран 10. Покрытие 90%-коридора на внешнем наборе . . . . . 32
Рис. 19 Экран 10. Согласие двух наборов на 166 общих играх . . . . . 32
Рис. 20 Экран 11. Медианы параметров по группам, разрез «цена» . . . . . 34
Рис. 21 Экран 11. CRPS финальной модели с базовой и расширенной регрессией плато, $L = 12$ . . . . . 34

# 1 Вопрос и данные

## 1.1 С чего начали

Исходный вопрос: как выглядит «жизнь» игры после выхода и можно ли по первым неделям сказать, что будет дальше. Лучшая мера жизни игры — число игроков, но история онлайна для новых игр почти не записана. Отзывы же есть с первой недели у каждой игры. Поэтому главный объект работы — **ряд отзывов по неделям**, а то, что он повторяет форму онлайна, проверено отдельно (раздел 10).

Первая версия плана (спека, написанная языковой моделью без просмотра данных) предлагала работать только с данными Mendeley о числе игроков. Осмотр данных показал, что так нельзя: запись онлайна начинается в декабре 2017, и почти ни у одной игры не видно начала жизни. Поэтому основным источником стал набор отзывов Anton Kozyriev с Kaggle, а Mendeley ушёл в проверки.

## 1.2 Наборы данных

- **Anton** (основной): каталог 50 872 игр и 41 млн отзывов с 15.10.2010 по 31.12.2022 для 37 610 игр. У каждого отзыва есть дата, игра и отметка «рекомендую / не рекомендую».
- **Mendeley**: онлайн 1851 игры каждые 5 минут (у около 175 игр раз в час), декабрь 2017 — август 2020.
- **najzeko** (Kaggle, 8 ГБ): 21,7 млн отзывов 315 популярных игр до января 2021. Использован в конце для внешней проверки (раздел 15).

## 1.3 Как из отзывов получился ряд

Для каждой игры: неделя 0 — неделя первого отзыва, дальше 104 недели (два года), внутри недели отзывы суммируются. Неделя выбрана как компромисс: по дням у небольших игр сплошные нули, по месяцам прячутся всплески.

> **Теория 1. Временной ряд счётчиков и цензурирование**
>
> Ряд $y_0, y_1, \ldots, y_{103}$ — это **счётчики**: целые неотрицательные числа. Обычная регрессия с нормальным шумом для них плоха: она допускает отрицательные значения и считает разброс одинаковым при 2 и при 2000 отзывах.
>
> **Цензурирование слева** — ситуация, когда начало наблюдаемого процесса не видно. Игра, вышедшая до начала записи (до 15.10.2010), имеет в данных «середину жизни» без старта. Такие игры нельзя смешивать с остальными: у них неделя 0 не означает начало. Они отделены в группу `censored` (412 игр) и в моделях не участвуют.
>
> **Смещение отбора** — когда правило отбора связано с изучаемой величиной. Порог «не меньше 200 отзывов» оставляет популярные игры, поэтому все выводы относятся к играм с заметной аудиторией, а не ко всему Steam.

Правила отбора (решения автора):

- не меньше 200 отзывов за всё время;
- первый отзыв не раньше даты релиза: иначе игра была в раннем доступе, и её начало не определено (1631 игра исключена);
- первый отзыв не позже 30 дней после релиза: иначе неизвестно, что было до первого отзыва (64 игры);
- игры, вышедшие до начала записи, в отдельной группе.

Итог: **основная группа 6821 игра**, из них **5311 с полным окном 104 недели** (у остальных запись кончается раньше). Почти все расчёты сделаны на этих 5311 играх.

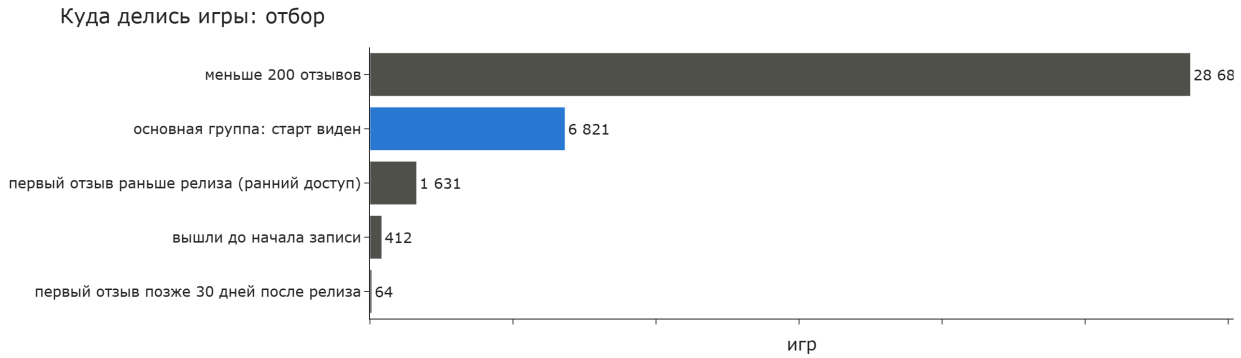



Рис. 1. Экран 1. Куда делись игры: отбор

**Как читать.** Горизонтальные столбцы — сколько игр ушло по каждой причине; синий столбец — основная группа, серые — исключённые и цензурированные. Самая большая потеря — игры с менее чем 200 отзывами (28 682): медиана числа отзывов на игру всего 39. График отвечает на вопрос «почему из 37 тысяч игр осталось 6,8 тысячи» и показывает, что отбор — по популярности.

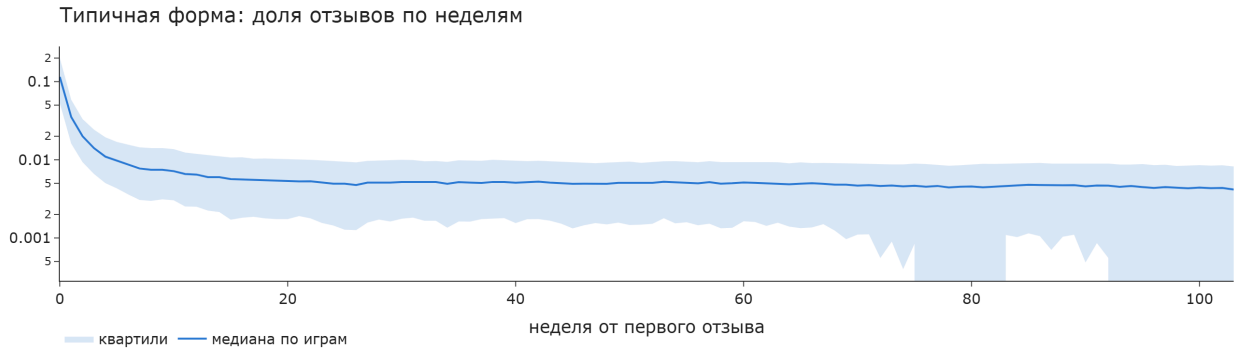



Рис. 2. Экран 1. Типичная форма: доля отзывов по неделям

**Как читать.** Для каждой из 5311 игр недельные отзывы поделены на сумму за 104 недели, то есть каждая игра приведена к сумме 1 и большие игры не перевешивают малые. Синяя линия — медиана этой доли по играм на каждой неделе, полоса — от 25-го до 75-го процентиля. Ось у логарифмическая: равные расстояния означают равные *отношения*. Видно три вещи: резкий пик на старте, быстрый спад в первые 10–20 недель и затем почти горизонтальный хвост. Этот хвост и есть **плато**, которое станет главным героем раздела 8. Факты из данных: у 69% игр пик в первые 8 недель, у 23% позже 26-й недели, у 13% позже года.

# 2 Три простые кривые

## 2.1 Что называется моделью

Модель в этой работе — правило, по которому компьютер может **породить** недельный ряд отзывов. У неё две части: средняя линия $\mu_t$ (формула от номера недели) и случайность вокруг неё.

Первые три кандидата на среднюю линию (выбор автора из предложенного):

$$\text{экспонента:} \quad \mu_t = Ae^{-\lambda t},$$

$$\text{степенной закон:} \quad \mu_t = A(1+t)^{-\alpha},$$

$$\text{логнормальная форма:} \quad \mu_t = A\exp\left(-\frac{(\ln(1+t)-m)^2}{2s^2}\right).$$

Экспонента теряет одну и ту же *долю* каждую неделю. Степенной закон спадает сначала быстро, потом всё медленнее: за неделю $1 \to 2$ уровень падает в $2^\alpha$ раз, а за неделю $50 \to 51$ почти не меняется. Логнормальная форма допускает пик не в нуле (подъём, потом спад); это форма кривой, а не плотность распределения.

**Теория 2. Отрицательное биномиальное распределение (NB)**

Случайность вокруг средней линии задаётся отрицательным биномиальным распределением с средним $\mu$ и параметром разброса $r > 0$:

$$P(Y=y) = \frac{\Gamma(y+r)}{\Gamma(r)\,y!}\left(\frac{r}{r+\mu}\right)^r\left(\frac{\mu}{r+\mu}\right)^y, \quad y = 0,1,2,\ldots$$

$$EY = \mu, \quad \operatorname{Var} Y = \mu + \frac{\mu^2}{r}.$$

Главное свойство — **избыточная дисперсия**: дисперсия больше среднего на $\frac{\mu^2}{r}$. Чем меньше $r$, тем сильнее разброс. При $r \to \infty$ слагаемое исчезает и получается распределение Пуассона ($\operatorname{Var} Y = \mu$). То есть Пуассон — частный случай NB.

**Почему не Пуассон.** У реальных рядов отзывов разброс в разы больше среднего: распродажа, обзор блогера, обновление дают всплески, которых пуассоновский шум не допускает. Данные отвергают Пуассон, поэтому NB.

Удобная интерпретация: NB — это Пуассон, у которого само среднее случайно (гамма-распределено). Каждая неделя «чуть лучше или хуже» средней по причинам, которых модель не знает.

**Теория 3. Метод максимального правдоподобия**

Параметры $\theta$ (например, $A, \alpha, r$) подбираются так, чтобы наблюдённый ряд был наиболее вероятен:

$$\ell(\theta) = \sum_{t=0}^{103} \log P(y_t \mid \mu_t(\theta), r), \quad \hat\theta = \arg\max_\theta \ell(\theta).$$

$\ell$ — логарифм правдоподобия. Максимум ищется численно (`scipy.optimize`), с нескольких стартовых точек, чтобы не застрять в локальном максимуме; параметры, которые должны быть положительными, оптимизируются в логарифмах. У каждого параметра есть границы; если оценка «упирается в границу», это сигнал, что данные параметр не определяют (это ещё встретится).

**Теория 4. AIC и BIC**

Чем больше параметров, тем выше правдоподобие, даже если лишние параметры подгоняют шум. Информационные критерии штрафуют за число параметров $k$:

$$\mathrm{AIC} = 2k - 2\ell\big(\hat{\theta}\big), \quad \mathrm{BIC} = k\ln n - 2\ell\big(\hat{\theta}\big),$$

где $n$ — число наблюдений. Меньше — лучше. BIC штрафует сильнее при $n > 7$. Оба отвечают на вопрос «какая модель лучше объясняет *этот* ряд», а не «какая лучше порождает похожие ряды» — разница станет главной темой раздела 3.

**Теория 5. Автокорреляция остатков**

Остаток недели — разница между фактом и средней линией, нормированная на стандартное отклонение: $e_t = \frac{y_t - \mu_t}{\sqrt{\mu_t + \frac{\mu_t^2}{r}}}$. Если модель учла всё, остатки соседних недель независимы. Автокорреляция первого порядка — корреляция между $e_t$ и $e_{t-1}$. Если она заметно больше нуля, недели «помнят» друг друга: после хорошей недели следующая тоже чаще хорошая. Модель без памяти этого не умеет.

## 2.2 Результат

Степенной закон лучше по AIC у 82,6% игр. Но все три кривые плохо передают первый всплеск, а автокорреляция остатков 0,26–0,32: модели не видят памяти между неделями. Отсюда следующий шаг — модель с памятью.

# 3 Как сравнивать модели: имитация и CRPS

## 3.1 Решение: главная проверка — имитация

Курс про имитационное моделирование, и автор решил сравнивать модели не только по правдоподобию, а по тому, **что они порождают**. Причина ещё и техническая: правдоподобие моделей с памятью (раздел 4) на каждой неделе использует *реальные* прошлые недели, то есть подсказку, которой у генератора нет.

### Теория 6. Свободная имитация (метод Монте-Карло)

Из подогнанной модели генерируется 200 рядов по 104 недели: на каждой неделе берётся $\mu_t$ и случайное число из $\mathrm{NB}(\mu_t, r)$. Для моделей с памятью $\mu_t$ считается по *сгенерированным* прошлым неделям, а не по реальным, — это и делает имитацию «свободной». Затем сравнивается не каждая неделя, а распределение характеристик 200 имитаций с характеристиками реального ряда.

Четыре характеристики траектории:

- **общее число отзывов** за 104 недели;
- **неделя пика** — неделя, с которой начинается 4-недельное окно с наибольшей суммой;
- **доля отзывов в первые 8 недель**;
- **t50** — неделя, к которой набирается половина всех отзывов.

Это и есть имитационная проверка модели: «если бы мир был устроен как модель, был бы наш ряд типичным?»

### Теория 7. Коридор 90% и покрытие

По 200 имитациям для каждой характеристики берутся 5-й и 95-й процентили; отрезок между ними — **90%-коридор**. Он ни вокруг чего не центрирован: это середина распределения имитаций. Затем по всем играм считается **покрытие** — доля игр, у которых факт попал в коридор.

Если модель честная, покрытие около 0,90. Меньше — модель **самоуверенна**: коридоры узкие, реальность часто выпадает. Заметно больше — коридоры шире, чем нужно. Покрытие проверяет калибровку, но не точность: коридор «от 0 до бесконечности» покрывает всё и бесполезен. Поэтому нужна ещё одна мера.

### Теория 8. CRPS — непрерывная ранжированная вероятностная оценка

CRPS сравнивает *распределение* прогноза $F$ с одним фактическим числом $x$:

$$\mathrm{CRPS}(F, x) = \int_{-\infty}^{\infty} (F(z) - \mathbb{1}\{z \geq x\})^2 \, \mathrm{d}z = E|X - x| - \frac{1}{2} E|X - X'|,$$

где $X, X'$ — две независимые величины из $F$. Первое слагаемое — насколько прогноз в среднем далёк от факта, второе — премия за ширину. В итоге CRPS одновременно наказывает и за промах, и за лишнюю ширину. Для точечного прогноза (все $X = c$) CRPS равен $|c - x|$, то есть это обобщение абсолютной ошибки на распределения; единицы те же, что у $x$. Меньше — лучше, идеал 0.

По ансамблю из $n = 200$ имитаций $x_1, \ldots, x_n$ используется несмещённая оценка

$$\widehat{\mathrm{CRPS}} = \frac{1}{n}\sum_i |x_i - x| - \frac{1}{2n(n-1)}\sum_{i\neq j}|x_i - x_j|.$$

**Шкала.** Общее число отзывов и все недельные прогнозы сравниваются на шкале $\log(1+y)$: иначе одна игра с 10 тысячами отзывов перевесила бы тысячу игр с сотней, а ошибка «вдвое» значит одно и то же для любой игры. Неделя пика и t50 — в неделях, доля — в долях. Поэтому CRPS разных характеристик между собой не сравниваются, сравниваются модели внутри одной характеристики.

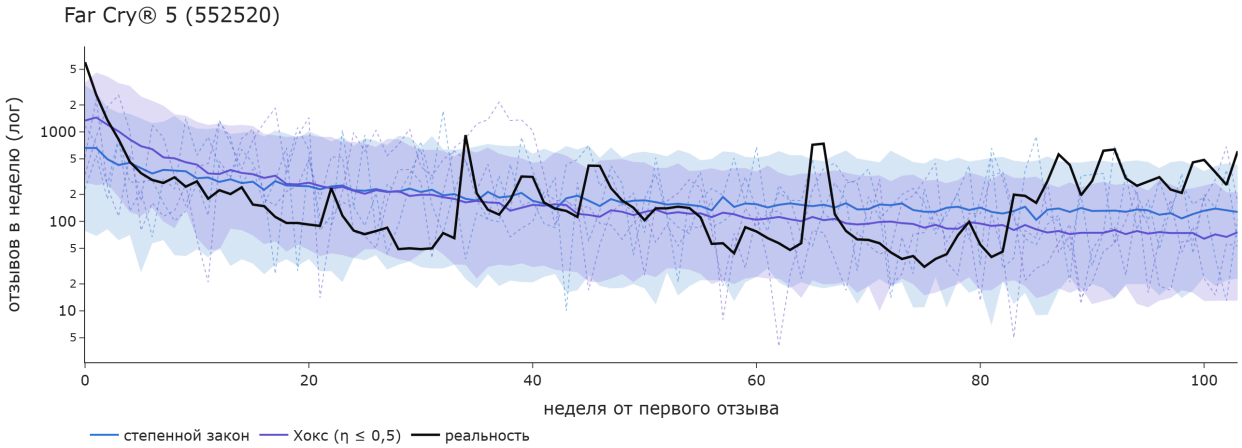



Рис. 3. Экран 2. Модель как генератор: имитации степенного закона и Хокса для Far Cry 5

**Как читать.** Чёрная линия — реальный ряд игры, ось y логарифмическая. Для каждой выбранной модели сплошная цветная линия — медиана 200 имитаций по неделям, полупрозрачная полоса — недельный 90%-коридор имитаций, пунктирные тонкие линии — отдельные имитации (их число задаётся ползунком). В приложении игру и модели можно выбрать. Под графиком таблица: для каждой модели и характеристики — факт, медиана имитаций, 90%-коридор и CRPS. На этом примере у Far Cry 5 доля первых 8 недель 0,40, а степенной закон порождает 0,10–0,30 (факт вне коридора, CRPS 0,18), Хокс — 0,2–0,5 (внутри, CRPS 0,05). Зато по t50 Хокс хуже: медиана 18 недель против факта 29. Это и есть картина раздела 5 в миниатюре: у каждой модели свои сильные характеристики.

# 4 Хокс: модель с памятью

**Теория 9. Процесс Хокса (самовозбуждающийся процесс)**

Идея: каждый отзыв (точнее, каждый новый игрок) порождает в будущем ещё немного отзывов — друзья, обсуждения, «сарафанное радио». Средняя линия в недельной версии:

$$\mu_t = B(1+t)^{-\alpha} + \eta s_t, \quad s_t = \sum_{k\geq 1} \rho^{k-1}(1-\rho)\, y_{t-k}.$$

Первое слагаемое — **фон**: внешний поток (реклама, витрина Steam), спадающий по степенному закону. Второе — **эхо**: взвешенная сумма прошлых недель с весами, затухающими в $\rho$ раз за неделю. Веса $(1-\rho)\rho^{k-1}$ в сумме дают 1, поэтому:

- $\eta$ — **коэффициент ветвления**: сколько будущих отзывов в среднем порождает один отзыв;
- $\frac{1}{1-\rho}$ — средняя «жизнь» эха в неделях.

При $\eta \geq 1$ процесс взрывается: каждый отзыв порождает больше одного, и ряд растёт без предела. Поэтому $\eta < 1$; ожидаемое число «потомков» одного отзыва во всех поколениях равно $\frac{\eta}{1-\eta}$, при $\eta = 0.5$ это 1, при $\eta = 0.99$ это 99. При $\eta = 0$ Хокс равен степенному закону; это вложенность использовалась для проверки подгонки (правдоподобие Хокса не должно быть ниже).

## 4.1 Результат и первая трещина

Хокс выигрывает по AIC у 66% игр, автокорреляция остатков падает до 0,04: память он поймал. Но у 9% игр $\eta$ упирается в верхнюю границу 0,99, а у четверти игр эхо живёт около недели. В свободной имитации коридоры Хокса на 20–65% шире, чем у простых кривых.

**Если спросят «почему не Хокс, раз он лучший по AIC?»** AIC измеряет, как модель объясняет уже виденный ряд, *имея его прошлое*. В свободной имитации эхо питается собственными случайными отклонениями: случайно хорошая неделя порождает ещё хорошие, и ошибки накапливаются. Чем ближе $\eta$ к 1, тем сильнее. Для прогноза важно, что модель порождает, а не как она объясняет.

## 4.2 Ограничение силы эха

Автор решил проверить, лечит ли ограничение $\eta$ расползание: варианты $\eta \leq 0.99$, 0.8, 0.5 (модели `hawkes`, `hawkes80`, `hawkes50`). Помогает частично: CRPS общего числа 0,092 → 0,083 → 0,072, выигрыш на доле старта сохраняется, но степенной закон по общему числу (0,055) остаётся лучше.

# 5 Толчки и итог первого блока

### Теория 10. Модель с толчками и скрытые переменные

Поверх `hawkes50` каждая неделя с вероятностью $p$ получает **толчок** — случайную добавку $S_t$ к среднему:

$$y_t \sim \begin{cases} \mathrm{NB}(\mu_t, r) & \text{с вероятностью } 1-p \\ \mathrm{NB}(\mu_t + S_t, r) & \text{с вероятностью } p \end{cases} \qquad \ln S_t \sim \mathcal{N}(m, s^2).$$

Толчок — модель распродажи или обновления: событие извне, после которого эхо разносит эффект.

Оценить такую модель можно двумя способами.

- **По правилу** (`shock_rule`): неделя объявляется толчком, если факт выше 99,5%-квантиля $\mathrm{NB}(\mu_t, r)$ минимум на 5 отзывов. Тогда $p$ — доля таких недель, а $m, s$ — среднее и стандартное отклонение логарифма превышения.
- **Совместно** (`shock_joint`): какая неделя толчок, не наблюдается — это **скрытая переменная**. Её «суммируют»: правдоподобие недели — смесь двух вариантов,

$$P(y_t) = (1-p)\, f(y_t \mid \mu_t) + p \int f(y_t \mid \mu_t + s)\, g(s)\, \mathrm{d}s,$$

где $g$ — логнормальная плотность размера; интеграл считается квадратурой Гаусса–Эрмита (взвешенная сумма в 20 узлах). Все параметры подгоняются вместе. При $p \to 0$ модель сводится к `hawkes50`, поэтому её правдоподобие не может быть ниже.

## 5.1 Результат

Толчки помогают только играм с поздним пиком (23% выборки) и вредят остальным: коридоры недели пика 86–88 недель против 26 у `hawkes50`. Совместная подгонка выигрывает по AIC у 56% игр, но в имитации хуже правила: она подбирает в среднем около 4 мелких толчков на игру (размер порядка 5 отзывов), то есть использует их как лишний шум. Снова правдоподобие и имитация расходятся.

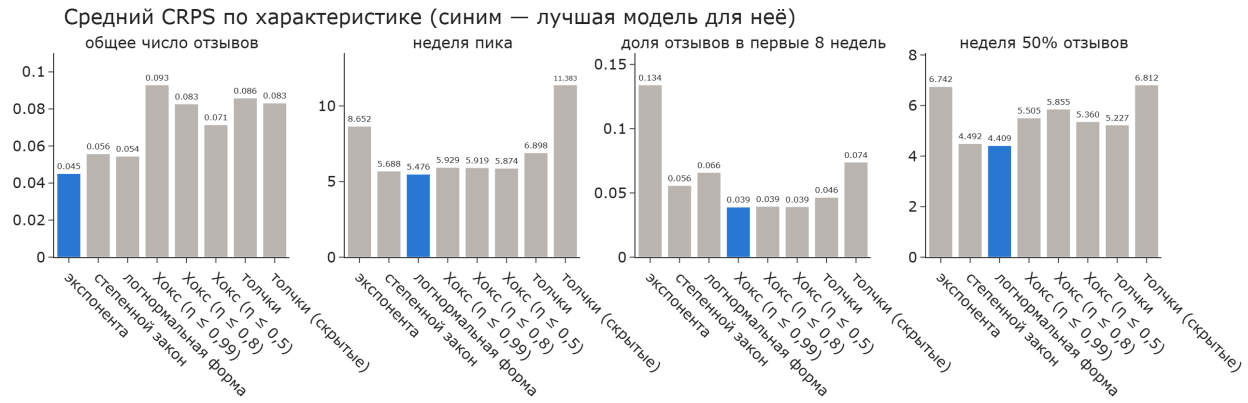



Рис. 4. Экран 3. Единой лучшей модели нет: средний CRPS по четырём характеристикам

**Как читать.** Четыре панели — четыре характеристики траектории. В каждой столбцы — восемь моделей, высота — средний по 5311 играм CRPS этой характеристики (меньше — лучше); синим выделена лучшая модель в панели. Сравнивать высоты можно только внутри панели: единицы разные (общее число на логарифмической шкале, неделя пика

и t50 в неделях, доля в долях). Вывод: по общему числу лучшая экспонента (0,045), по неделе пика и по t50 логнормальная (5,5 и 4,4 недели), по доле старта Хокс (0,039). Толчки со скрытыми переменными худшие по неделе пика (11,4). Ни одна модель не выигрывает везде.

Под графиком в приложении таблица покрытия: доля игр, у которых факт внутри 90%-коридора, для каждой модели и характеристики (идеал 0,90). Например, экспонента по доле старта покрывает только 26% игр — она не умеет быстрый начальный спад; Хокс и толчки по правилу 0,90–0,92. По общему числу все модели дают 0,96–0,99: эта характеристика подогнана ко всем 104 неделям сразу и слабо различает модели.

**Важно помнить на защите:** экран 3 — проверка *подгонки*, а не прогноза. Модель видела все 104 недели той же игры. Настоящий прогноз на невиденные недели — раздел 7 и дальше.

**Итог первого блока.** Одной формулой жизнь игры не описывается; модель, лучше объясняющая ряд, не обязательно лучше его порождает. Это честный результат, а не провал.

# 6 Типы траекторий

Спека обещала типы игр: «хайп», «устойчивая», «возвращение». Проверка шла так, чтобы не обмануть себя: три способа описать игру, два метода кластеризации, контроль на данных без структуры и проверка предсказуемости без утечки.

### Теория 11. Кластеризация: k-means и метод Уорда

Каждая игра описывается вектором признаков. **k-means** делит игры на $k$ групп так, чтобы минимизировать сумму квадратов расстояний до центра своей группы:

$$\min \sum_{j=1}^{k} \sum_{i \in G_j} \|x_i - c_j\|^2.$$

**Метод Уорда** — иерархический: начинает с отдельных игр и на каждом шаге сливает две группы, слияние которых меньше всего увеличивает ту же сумму квадратов. Если оба метода дают похожие группы, группы скорее настоящие.

Три описания игры: **форма** (доли отзывов по 4-недельным блокам), **сводные** (несколько чисел вроде доли старта и t50), **параметры** подогнанного `hawkes50`.

### Теория 12. Как проверить, что кластеры не выдуманы

Кластеризация *всегда* выдаёт $k$ групп, даже на случайных данных. Поэтому нужны проверки.

- **Силуэт**: для игры $i$ пусть $a$ — среднее расстояние до своей группы, $b$ — до ближайшей чужой; $s_i = \frac{b-a}{\max(a,b)}$. Среднее по играм от $-1$ до 1; чем больше, тем лучше разделены группы.
- **Контроль без структуры**: генерируются гауссовы данные с теми же средними и ковариациями признаков, но без групп, и на них считается тот же силуэт. Если у реальных данных силуэт такой же, как у шума, группы ничего не значат.
- **Устойчивость**: кластеризация на случайных подвыборках должна давать те же группы.
- **Согласие разных описаний** — скорректированный индекс Рэнда (ARI): 1 при полном совпадении разбиений, около 0 при случайном.
- **Метод главных компонент (PCA)**: сколько независимых направлений в данных. Если одна компонента объясняет почти всё, «типы» — это просто положение на одной шкале.

### Теория 13. Утечка и честная проверка предсказуемости

**Утечка** — когда при проверке модели в её входы просачивается то, что она должна предсказать. Первая версия скрипта строила типы по всем 104 неделям и проверяла, предсказывается ли тип по неделям 0–11. Но недели 0–11 входят в определение типа, поэтому предсказуемость была отчасти тавтологией (macro-F1 0,77 против базовой 0,39).

Исправленная версия строит типы только по «будущему» — неделям 12–103 — и предсказывает их по неделям 0–11.

**Macro-F1**: для каждого типа считается F1 — гармоническое среднее точности (доли верных среди предсказанных этим типом) и полноты (доли найденных среди настоящих), затем F1 усредняются по типам без весов. Так редкий тип важен наравне с частым.

**Базовая линия** — «случайное угадывание» с частотами типов: то, что можно получить, ничего не зная об игре.

**Внешняя проверка**: связаны ли типы с тем, чего модель не видела. **V Крамера** — сила связи двух категориальных признаков (тип и жанр), от 0 до 1. $\varepsilon^2$ — доля разброса числового признака (цены, рейтинга), объяснённая типом.

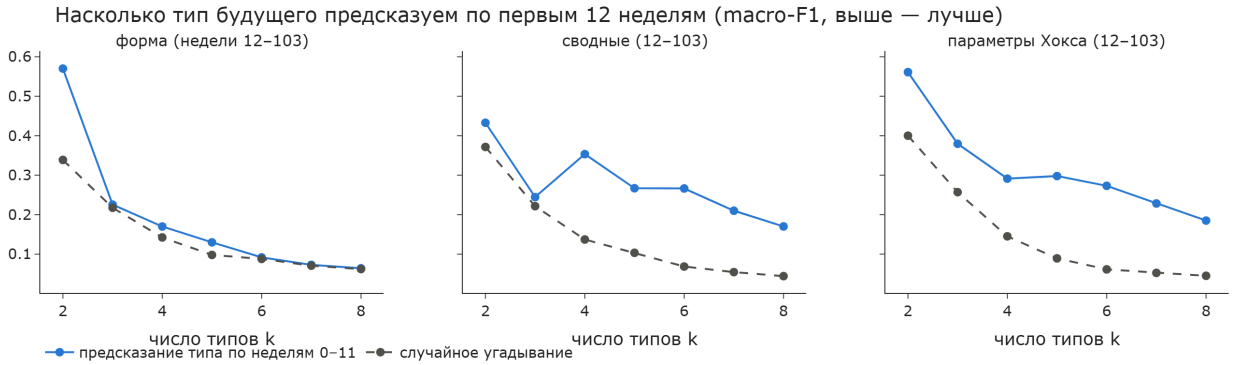



Рис. 5. Экран 4. Насколько тип будущего предсказуем по первым 12 неделям

**Как читать.** Три панели — три описания игры, все построены только по неделям 12–103. По оси x — число типов $k$, по оси y — macro-F1 предсказания типа по неделям 0–11 (синяя линия) и случайного угадывания (серый пунктир). Выше — лучше. Если синяя линия почти совпадает с серой, тип будущего по началу не предсказывается. Форма: при $k = 2$ 0,57 против 0,34, при $k = 3$ уже 0,23 против 0,22 — выигрыша нет. У сводных и параметров при $k \geq 4$ выигрыш в 2–3 раза, но абсолютные значения малы (0,2–0,4).

Под графиком три числа: силуэт формы будущего 0,085 против 0,082 у шума — форма будущего неотличима от данных без структуры; только 30% игр имеют параметры Хокса строго внутри границ — кластеры по параметрам во многом отражают упор в границы; связь типа с жанром слабая (V Крамера 0,06–0,15), с ценой и рейтингом почти нулевая.

**Итог.** Устойчиво только грубое деление на две группы по доле отзывов на старте (первая главная компонента формы по всем неделям объясняет 55%). Типы в духе спеки данные не поддерживают — это тоже результат.

# 7 Прогноз на отложенных неделях

## 7.1 Постановка

До этого места все проверки были **внутривыборочными**: модель видела весь ряд. Главная практическая проверка — прогноз: подогнать модель по неделям $0, ..., L-1$ ($L = 12$ или 26), сгенерировать 200 продолжений на недели $L, ..., 103$ и сравнить с фактом.

### Теория 14. Обучающая и проверочная части, фолды

**Отложенные данные** — то, что модель не видела при подгонке. Ошибка на них честно показывает качество прогноза; ошибка на обучающих данных занижена, потому что модель под них подстроена.

Некоторые прогнозы используют **популяцию** — другие игры (шаблон, плато, соседи). Чтобы проверяемая игра не участвовала в оценке популяционных величин, игры случайно делятся на 5 **фолдов** (частей). Всё популяционное считается по четырём фолдам и применяется к пятому, затем роли меняются. Так каждая игра прогнозируется моделью, которая её никогда не видела. Это перекрёстная проверка.

### Теория 15. Простые планки (базовые прогнозы)

Сложную модель нужно сравнивать с простыми прогнозами, иначе неясно, стоит ли она чего-то.

- **Плоская планка**: будущее равно среднему уровню последних 8 обучающих недель, с NB-разбросом.
- **Шаблон**: средняя форма будущего у других игр. По играм других фолдов считается доля будущей недели $h$ от суммы первых $L$ недель:

$$\tau_h = \frac{\sum_j y_{j,h}}{\sum_j S_j}, \quad S_j = \sum_{t<L} y_{j,t},$$

и прогноз для игры с объёмом $S$ — $\mu_h = S\tau_h$ с общим для популяции $r$. Шаблон ничего не знает о форме конкретной игры, кроме её размера.

### Теория 16. Горизонты, CRPS суммы и бутстреп парных разностей

Недельный CRPS считается на шкале $\log(1+y)$ и усредняется по горизонтам: недели 12–25, 26–51, 52–103. Отдельно — **CRPS суммы**: для каждой имитации складываются все прогнозные недели, и распределение $\log(1+\text{сумма})$ сравнивается с фактической суммой. Сумма проверяет, верно ли угадан общий объём будущего, недельный CRPS — форма.

**Парная разность**: для каждой игры $d_i = \text{CRPS}_i^A - \text{CRPS}_i^B$. Модели сравниваются на одних и тех же играх, поэтому разброс между играми (одни прогнозировать легче) сокращается. **Бутстреп**: 2000 раз выбираем игры с возвращением, считаем среднее $d$; 2,5-й и 97,5-й процентили этих средних — 95%-доверительный интервал. Если он не включает 0, разница не случайна.

## 7.2 Результат: кривые уходят в ноль

При обучении по 12 неделям CRPS суммы: шаблон 0,69, плоская 0,76, `hawkes50` 1,50, степенной 1,56, логнормальная 2,08, экспонента 3,04. **Все подогнанные кривые проигрывают даже плоской планке.** Только на ближнем горизонте 12–25 степенной и Хокс чуть лучше

шаблона. Покрытие кривых падает к дальнему горизонту до 0,52–0,54 (экспонента 0,30) — они самоуверенны. При $L = 26$ разрыв меньше, порядок тот же.

Причина видна на картинке: кривые, подогнанные к ранним неделям спада, продолжают спад до нуля, а реальные игры выходят на **плато** — уровень порядка 2% стартового объёма в неделю. У моделей нет слагаемого «долгосрочный уровень».

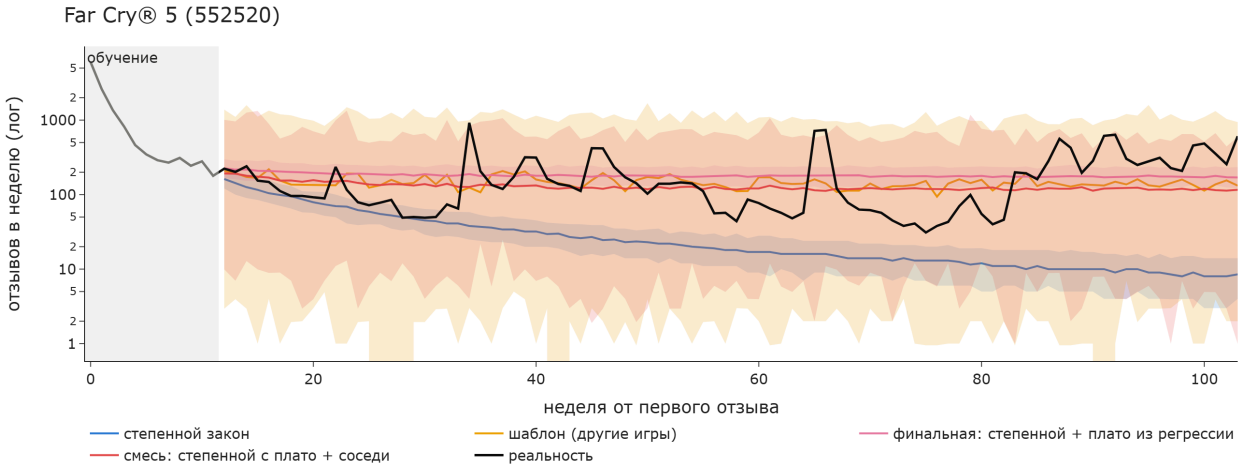



Рис. 6. Экран 5. Прогноз всей кривой по первым 12 неделям для Far Cry 5

**Как читать.** Серая область слева — 12 обучающих недель; модели видели только их. Чёрная линия — реальность за все 104 недели. Для каждой модели цветная линия — медиана 200 прогнозных имитаций, полоса — недельный 90%-коридор. Ось у логарифмическая. Синий степенной закон продолжает спад: к 100-й неделе его медиана около 8 отзывов в неделю при реальных 100–500, и реальность выходит из его коридора. Шаблон (жёлтый), финальная модель (розовая) и смесь (красная) держат уровень около 100–200 — правильный порядок. Резкие всплески (недели 34, 65) — распродажи и обновления; их не предсказывает никто, они попадают в широкие коридоры шаблона и смеси.

Под графиком в приложении таблица CRPS этой игры по горизонтам. Для Far Cry 5 CRPS суммы: степенной 1,76, шаблон 0,36, смесь 0,15, финальная 0,03. Подпись под таблицей даёт плато для этой игры: из популяции, из регрессии и реальный уровень недель 78–103. Игру, $L$ и модели можно выбрать; всё популяционное считается по другим фолдам, выбранная игра в нём не участвует.

# 8 Плато

## 8.1 Три способа задать плато

Решение автора: добавить к степенному закону слагаемое $C$,

$$\mu_t = A(1+t)^{-\alpha} + C,$$

и сравнить три способа его задать.

- **Свободное** (`power_c_free`): $C$ подгоняется по игре вместе с остальными параметрами.
- **Из популяции** (`power_c_pop`): $C = \kappa S$, где $\kappa$ — медиана по играм других фолдов отношения «средний уровень недель 78–103 / сумма первых $L$ недель». $\kappa \approx 0.021$ при $L = 12$.
- **Со сжатием** (`power_c_shrink`): $C$ подгоняется по игре, но со штрафом за отход от популяционного значения.

> **Теория 17. Сжатие (штрафованное правдоподобие)**
>
> Вместо максимума $\ell(\theta)$ ищется минимум
>
> $$-\ell(\theta) + \frac{(\ln C - \ln(\kappa S))^2}{2\sigma^2},$$
>
> где $\sigma$ — разброс $\ln\left(\frac{\text{плато}}{S}\right)$ по другим играм ($\approx 1.2$). Если данные игры ясно говорят о своём плато, правдоподобие перевешивает штраф; если данные молчат, оценка остаётся около популяционной.
>
> Байесовский смысл: это **апостериорный максимум** при априорном распределении $\ln C \sim \mathcal{N}(\ln \kappa S, \sigma^2)$, то есть «до просмотра игры мы думаем, что её плато как у похожих по размеру игр, с таким-то разбросом». Свободное $C$ — частный случай с $\sigma \to \infty$, популяционное — с $\sigma \to 0$. Сжатие — середина между «верю только игре» и «верю только популяции».

## 8.2 Результат

- Плато чинит главный провал: при $L = 12$ CRPS суммы `power_c_pop` 0,687, `power_c_shrink` 0,697 против шаблона 0,691 и голого степенного 1,559.
- Откуда брать $C$, решает всё: свободное $C$ лучше голого степенного, но хуже шаблона (+0,23). Корреляция Спирмена найденного $C$ с реальным уровнем 0,38, у 19% игр $C$ уходит в ноль. У популяционного и сжатого 0,63–0,64.
- По 26 неделям информация игры начинает помогать: лучший `power_c_shrink` 0,549 против шаблона 0,600 (разность −0,050 [−0,063; −0,037]).

**Ответ на вопрос «информация из игры или из популяции»:** по 12 неделям из популяции (плато из игры не определяется), по 26 неделям из обоих источников через сжатие.

> **Теория 18. Идентифицируемость**
>
> Параметры **идентифицируемы**, если разные значения параметров дают заметно разные распределения данных. По 12 неделям спада плато почти не видно: ряд «спадает и ещё не остановился». Одинаково хорошо подходят «медленный спад без плато» (малое $C$, малое $\alpha$) и «быстрый спад к высокому плато» (большое $C$, большое $\alpha$). Параметры $\alpha$ и $C$ компенсируют друг друга, правдоподобие почти плоское вдоль этой линии, и оптимизатор может уйти куда угодно, в том числе на границу $C \approx 0$. Это проверено прямо в разделе 12.

# 9 Шесть недорогих улучшений и финальная модель

Решение автора: сделать все шесть улучшений, каждое отдельной моделью, и сравнить. Точка отсчёта: `power_c_shrink` (CRPS суммы 0,698, покрытие 0,81 / 0,76 / 0,74 по горизонтам) и шаблон (0,691, покрытие 0,91–0,93).

## 9.1 Улучшения калибровки

### Теория 19. Общий разброс из популяции

Параметр $r$ одной игры по 12 точкам оценивается плохо и обычно завышен: начало ряда гладкое, а дальше бывают всплески. Вместо него берётся одно $r$, подогнанное максимумом правдоподобия по всем будущим неделям игр других фолдов при их прогнозных средних ($r \approx 0.42$). Модель `shrink_rpop`: покрытие 0,94 / 0,92 / 0,91, но CRPS ближних горизонтов хуже (коридоры стали шире, чем нужно для крупных игр).

### Теория 20. Конформная калибровка

Простой способ исправить самоуверенность, не меняя модель. На играх других фолдов для каждой прогнозной недели считается, во сколько раз нужно растянуть половину коридора вокруг медианы, чтобы накрыть факт (на шкале $z = \log(1 + y)$):

$$s = \begin{cases} \frac{z - q_{50}}{q_{95} - q_{50}} & \text{если } z \geq q_{50} \\ \frac{q_{50} - z}{q_{50} - q_{05}} & \text{если } z < q_{50}. \end{cases}$$

**Конформный множитель** $s^*$ — 90%-квантиль этих $s$ по всем неделям всех чужих игр. Затем каждая имитация проверяемой игры растягивается вокруг медианы: $\tilde{z} = q_{50} + s^*(z - q_{50})$. По построению растянутые коридоры накрывают около 90% недель на новых играх — это гарантия **расщеплённой конформной процедуры**, если новые игры похожи на старые.

Для `power_c_shrink` $s^* = 2.0$ при $L = 12$ и 1,37 при $L = 26$; покрытие 0,94 / 0,91 / 0,90. Множитель 2,0 одинаков во всех фолдах — артефакт дискретности малых счётчиков: медиана имитаций 0, $q_{95} = 1$, факт 3 дают ровно 2 на шкале $\log(1 + y)$.

### Теория 21. Приближение Лапласа (неопределённость параметров)

Обычная имитация берёт одну оценку $\hat{\theta}$ и порождает данные только из неё, как будто параметры известны точно. Отсюда часть самоуверенности. Приближение Лапласа считает распределение параметров нормальным вокруг оценки:

$$\theta \sim \mathcal{N}\left(\hat{\theta}, H^{-1}\right), \quad H = \nabla^2(-\ell(\theta))\,|_{\hat{\theta}},$$

где $H$ — матрица вторых производных отрицательного логарифма правдоподобия (кривизна в максимуме: чем острее пик, тем точнее параметры). Для каждой имитации сначала берётся свой $\theta$, затем ряд. Модель `shrink_laplace` (доступна для 96% игр): покрытие 0,87 / 0,85 / 0,84, CRPS суммы сильно лучше (0,572). Это калибровка «по причине», но по 12 неделям она закрывает не всю ширину.

## 9.2 Улучшения точности

### Теория 22. Регрессия плато

Плато берётся не как одна медиана $\kappa$, а из линейной регрессии по играм других фолдов:

$$\ln\left(\frac{\text{плато}}{S}\right) = \beta_0 + \beta_1 \ln S + \gamma_{\text{жанр}} + \varepsilon.$$

Прогноз для игры: $\hat{\kappa} = \exp\left(\beta_0 + \beta_1 \ln S + \gamma_{\text{жанр}}\right)$, плато $C = \hat{\kappa} S$. Жанр — первый тег игры в Steam.

**Как читать $\beta_1$.** Модель в логарифмах — степенная зависимость: плато $\propto S^{1+\beta_1}$. Оценка $\beta_1 \approx -0.45$, то есть плато растёт как $S^{0.55}$: вдесятеро больший старт даёт плато лишь в $10^{0.55} \approx 3.5$ раза выше. Крупные игры удерживают меньшую *долю* стартового объёма. Объяснение для защиты: у крупных игр старт раздут рекламой и хайпом, у малых стартовый объём ближе к «ядру» аудитории. Жанр добавляет мало.

Модель `power_c_reg` (плато из регрессии, зафиксированное) лучше `shrink` везде: −0,013 / −0,029 / −0,042 по неделям, −0,121 по сумме. Вариант со сжатием к регрессионному плато хуже фиксированного: по 12 неделям данные самой игры только мешают.

### Теория 23. Шаблон по ближайшим соседям

Вместо средней формы *всех* игр берётся форма 50 игр других фолдов, начало которых больше всего похоже на начало данной игры. Расстояние — евклидово между векторами $\log(1 + y_t)$ первых $L$ недель. Доли будущих недель $\tau_h^{\text{knn}}$ считаются по этим соседям так же, как у шаблона. Модель `template_knn` лучше обычного шаблона на всех горизонтах (CRPS суммы 0,584). Это «память» о похожих играх.

### Теория 24. Смесь предиктивных распределений

**Смесь** `mix_shrink_knn`: из 200 имитаций 100 порождаются моделью `power_c_shrink`, 100 — шаблоном по соседям; квантили и CRPS считаются по объединённым 200 траекториям. Это равновесная смесь распределений

$$F_{\text{mix}} = \frac{1}{2} F_1 + \frac{1}{2} F_2,$$

а **не среднее двух кривых**. Если одна модель говорит «около 10», а другая «около 100», смесь говорит «скорее 10 или 100», а среднее кривых — «55», что может быть неверно обеими.

**Почему смесь не хуже своих частей в среднем.** CRPS выпукл по $F$ (он — интеграл квадрата выражения, линейного по $F$), поэтому

$$\text{CRPS}\left(\frac{1}{2} F_1 + \frac{1}{2} F_2, x\right) \le \frac{1}{2}\,\text{CRPS}(F_1, x) + \frac{1}{2}\,\text{CRPS}(F_2, x).$$

Смесь всегда не хуже среднего своих двух членов, а когда члены ошибаются по-разному, заметно лучше обоих.

Веса 50/50 **не оптимизировались** намеренно: подбор на тех же играх был бы отчасти подгонкой. Это заранее заданное правило.

Смесь лучшая везде: CRPS по неделям 0,407 / 0,449 / 0,472, суммы 0,513 против 0,69–0,70 у обоих её членов, покрытие 0,95 / 0,94 / 0,94.

## 9.3 Финальная модель (решение автора)

Автор выбрал **одну формулу**, которую можно записать и объяснить одной строкой:

$$y_t \sim \mathrm{NB}(\mu_t, r), \quad \mu_t = A(1+t)^{-\alpha} + \hat{\kappa} S,$$

где $A, \alpha, r$ подгоняются по первым $L$ неделям игры, $S$ — число отзывов за эти недели, а $\hat{\kappa}$ — из регрессии плато по другим играм. По 12 неделям CRPS суммы 0,577 (шаблон 0,691). Смесь остаётся в работе как «лучший достижимый прогноз» для сравнения, с однозначным описанием выше.

**Калибровка финальной модели** (`reg_conf`): конформный множитель 1,67–1,71 при $L = 12$ и 1,20–1,22 при $L = 26$ — меньше, чем у `shrink`, потому что регрессионное плато само снимает часть самоуверенности. Покрытие недельных коридоров 0,92 / 0,90 / 0,89 (было 0,85 / 0,82 / 0,80), недельный CRPS не изменился. Растяжение ухудшает CRPS суммы (0,661 против 0,577), потому что множитель подобран под недельные коридоры. Поэтому множитель применяется только к недельным коридорам, прогноз суммы — без растяжения.

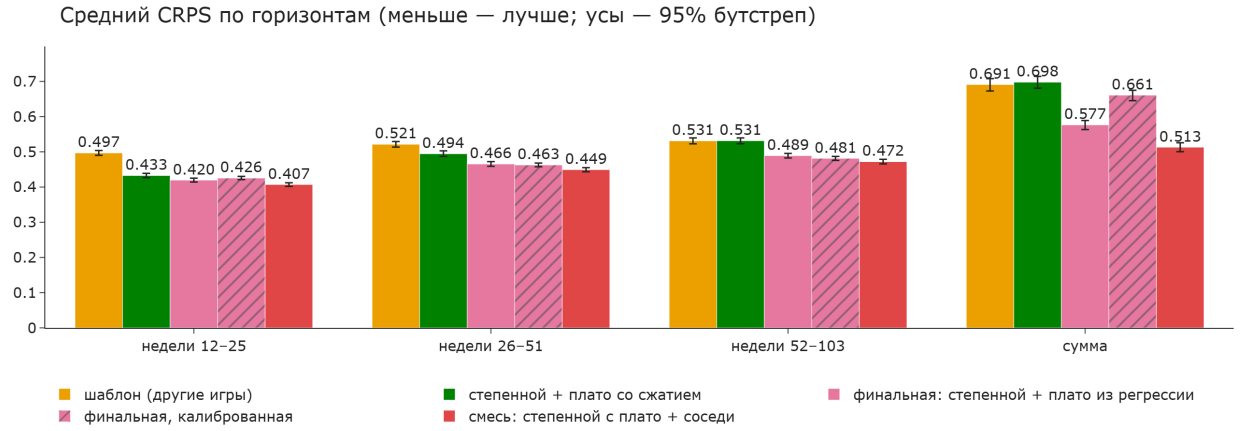



Рис. 7. Экран 7. Средний CRPS финальной модели и конкурентов по горизонтам, $L = 12$

**Как читать.** Группы столбцов — горизонты (недели 12–25, 26–51, 52–103) и сумма за прогнозное окно; внутри группы — пять моделей: шаблон (жёлтый), `power_c_shrink` (зелёный), финальная (розовая), финальная калиброванная (розовая со штриховкой), смесь (красная). Высота — средний CRPS по 5311 играм (меньше — лучше), усы — 95%-интервал бутстрепа среднего. Усы маленькие, потому что игр много: почти все различия значимы. Смесь (красная) ниже всех на всех горизонтах. Финальная (розовая) лучше шаблона и `shrink` везде. Калиброванная по неделям почти равна некалиброванной, а по сумме заметно хуже — именно поэтому растяжение применяется только к недельным коридорам. Переключатель $L$ показывает то же для 26 недель.

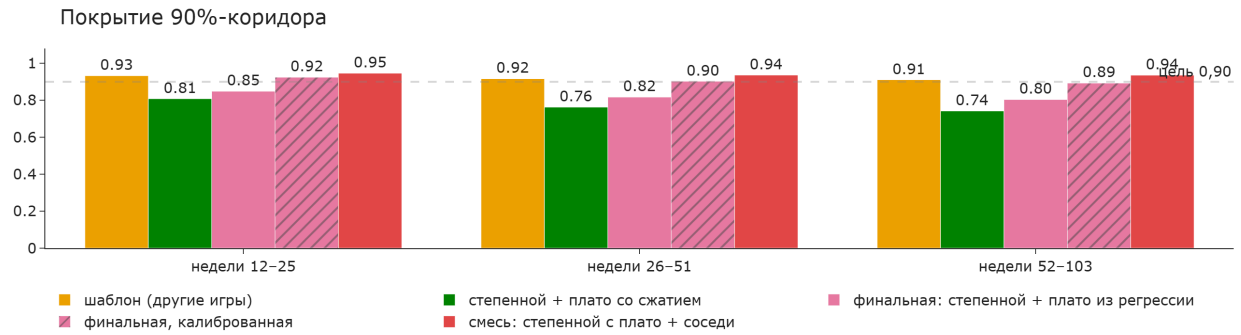



Рис. 8. Экран 7. Покрытие 90%-коридора, $L = 12$

**Как читать.** Те же модели и горизонты, высота — доля прогнозных недель, у которых факт внутри недельного 90%-коридора. Пунктир — цель 0,90. Некалиброванные `shrink` и финальная ниже цели (самоуверенны, 0,74–0,85), калиброванная финальная на цели (0,92 / 0,90 / 0,89), шаблон и смесь чуть выше (0,91–0,95, слегка широковаты). Читать вместе с предыдущим рисунком: хорошая модель и точна (низкий CRPS), и откалибрована (покрытие около 0,90).

# 10 Проверка «отзывы вместо игроков» (M1)

Вопрос: повторяет ли недельное число отзывов форму недельного онлайна. Решение автора: важна **форма**, а не масштаб. Для 338 игр с общими неделями онлайн Mendeley усреднён по неделям отзывов каждой игры (неделя засчитывается при ≥ 4 днях данных, день — при ≥ 12 замерах).

### Теория 25. Корреляции уровней и изменений

- **Спирмен по уровням**: корреляция рангов $\log(1 + y_t)$ отзывов и онлайна. Ранговая — потому что нечувствительна к форме зависимости и выбросам.
- **Пирсон по изменениям**: корреляция недельных приростов $\Delta \log y_t = \log y_t - \log y_{t-1}$. Уровни двух спадающих рядов коррелируют почти всегда — оба спадают, и это ничего не говорит о связи. Изменения убирают общий тренд и проверяют, совпадают ли *всплески и провалы* неделя в неделю. Это более строгая проверка.
- **Кросс-корреляция с лагом**: та же корреляция изменений при сдвиге одного ряда на $-4, \ldots, 4$ недели. Лучший сдвиг 0 значит, что отзывы не запаздывают за онлайном.

### Теория 26. Контроль на перестановках и заранее зафиксированный критерий

Сама по себе корреляция 0,4 ни о чём не говорит: общие для всех события (распродажи Steam, праздники, карантин 2020) двигают все игры одновременно. **Контроль**: отзывы игры сравниваются с онлайном 40 случайных *других* игр на тех же календарных неделях. Это распределение того, что дают общие события без связи «именно эта игра». Если своя корреляция выше 95-го процентиля контроля, связь специфична для игры.

**Предрегистрация**: критерий «хорошо» записан до расчёта — медиана корреляции изменений выше медианы контроля, и не меньше половины игр выше своего 95-го процентиля. Так нельзя подогнать критерий под результат.

## 10.1 Результат

Спирмен уровней: медиана 0,60 против 0,21 у контроля, 72% игр выше своего 95-го процентиля. Корреляция изменений 0,42 против 0,09, 67% игр. Оба условия выполнены. Лучший сдвиг 0 у 75% игр. Масштаб не переносится: 76 отзывов на 1000 игроко-недель по медиане, но от 13 до 359 между играми (в 27 раз). Связь растёт с объёмом: у игр с 2 отзывами в неделю это шум (медиана 0,14), с 8 и больше пригодно (0,39–0,59).

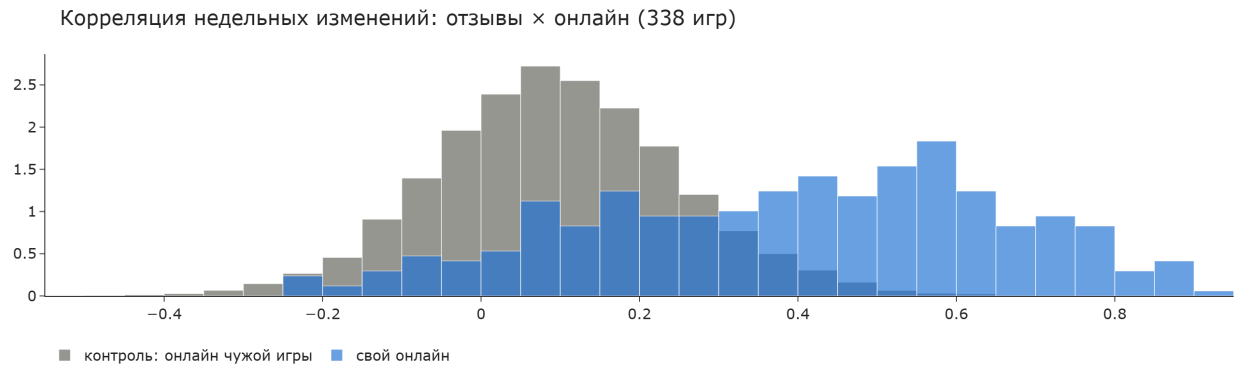



Рис. 9. Экран 8. Корреляция недельных изменений отзывов и онлайна, 338 игр

**Как читать.** Две наложенные гистограммы плотности. Синяя — корреляции изменений отзывов игры с её *собственным* онлайном, по одной на игру. Серая — контроль: те же отзывы против онлайна случайных чужих игр на тех же неделях. Если бы отзывы не повторяли онлайн, синяя совпала бы с серой. Серая сосредоточена около 0 (медиана 0,09), синяя сдвинута вправо (медиана 0,42). Под графиком три числа: медианы, доля игр выше 95-го процентиля своего контроля (67%) и доля игр с лучшим сдвигом 0 (75%).

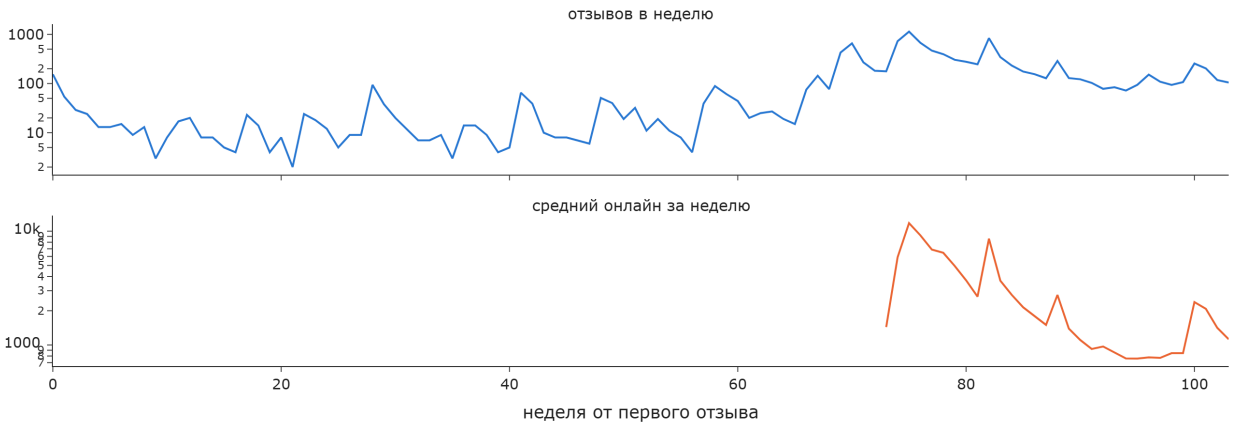



Рис. 10. Экран 8. Пример: отзывы и онлайн одной игры на общих неделях

**Как читать.** Две панели с общей осью недель: сверху отзывы в неделю, снизу средний онлайн, обе на логарифмической шкале. Две панели вместо двух осей у на одном графике — сознательно: у величин разный масштаб. Онлайн начинается не с недели 0, а с момента начала записи Mendeley (декабрь 2017), поэтому сравнивается только общая часть. В приложении игры отсортированы по корреляции изменений, по умолчанию показана самая согласованная: пики онлайна на неделях 75, 82, 88, 100 повторяются в отзывах в ту же неделю.

# 11 Те же модели на числе игроков (M2)

Хотели проверить модели на играх с видимым стартом онлайна. Оказалось, что все 69 игр, «вышедших» внутри записи Mendeley, — игры раннего доступа (у 68 онлайн есть до даты релиза). Автор принял замену постановки:

- **release**: 62 игры, неделя 0 — выход из раннего доступа, окно 72 недели, обучение 12 недель. Уровень до релиза известен, что даёт прямой тест идеи плато: модель `power_c_known` с $C$, равным дорелизному уровню.
- **record**: 1454 зрелые игры, неделя 0 — начало записи, окно 104 недели, обучение 26 недель.

Недельное значение — средний онлайн, округлённый до целого; NB здесь рабочая модель разброса «дисперсия растёт с уровнем», а не модель счёта.

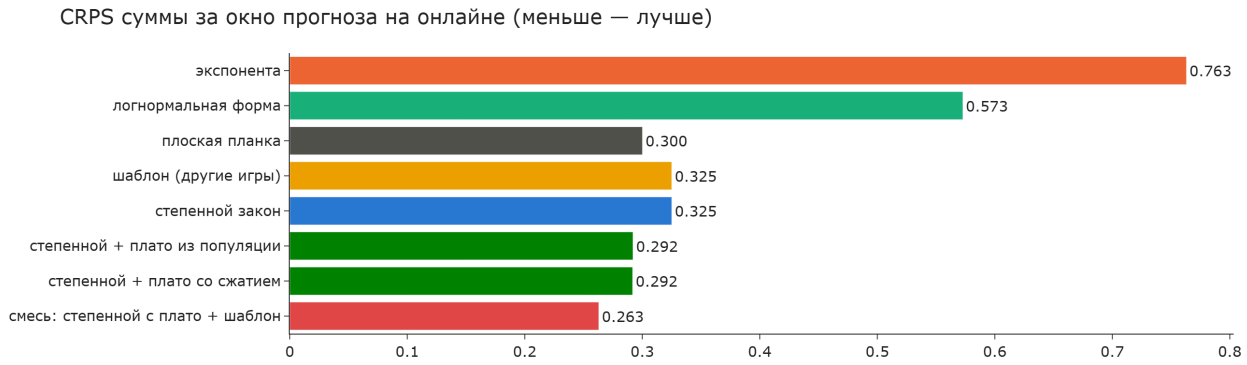



Рис. 11. Экран 8. CRPS суммы за окно прогноза на онлайне

**Как читать.** Горизонтальные столбцы — модели, длина — средний CRPS суммы прогноза (меньше — лучше). Переключатель выбирает постановку; на рисунке **record**. Ранжирование повторяет отзывы: экспонента и логнормальная хуже всех (уводят ряд к нулю), плато из популяции и со сжатием лучше шаблона, смесь `mix_shrink_template` лучшая (0,263 в **record**, 0,403 в **release**). Подпись под графиком: в **release** известный старый уровень не помогает — после выхода из раннего доступа игра выходит на новый уровень (у 48% выше старого; отношение от 0,64 до 1,74 между квартилями). В **record** зрелые игры за два года теряют около 30% игроков, и наивная планка здесь сильна.

**Слабое место, назвать самому:** покрытие параметрических моделей на онлайне 0,3–0,76. Внутри обучающего окна недельные средние гладкие, подогнанное $r$ большое, а дальше распродажи и обновления дают всплески в 2–3 раза. Калибровка на онлайн не переносилась.

# 12 Восстановление параметров имитацией

## 12.1 Зачем

На реальных играх истинное плато неизвестно, поэтому нельзя прямо сказать, ошибается ли оценка $C$. Решение: использовать модель как генератор, где истина известна по построению.

**Теория 27. Эксперимент по восстановлению параметров**

1. **Истины**: свободная подгонка $A(1+t)^{-\alpha}+C$ по всем 104 неделям у 400 случайных игр. У 79 из них $C$ на нижней границе (плато нет даже по двум годам); они отброшены, осталась 321 истина.
2. **Генерация**: из каждой истины 20 искусственных игр по 104 недели из $\mathrm{NB}(\mu_t, r)$ — 6420 рядов с известными параметрами.
3. **Оценка**: подгонка по первым 12 и 26 неделям тремя способами (свободное, популяционное, сжатие). Правило $\kappa S$ и $\sigma$ оцениваются по самой искусственной популяции, чтобы популяционные способы не страдали от несовпадения популяций.
4. **Сравнение**: ошибка $\log\left(\frac{\hat{C}}{C}\right)$, доля оценок на границе, ошибка прогноза суммы недель $L, \ldots, 103$.

Ожидание записано до запуска: по 12 неделям свободное $C$ не восстанавливается, по 26 восстанавливается с разбросом, сжатие даёт наименьшую ошибку прогноза. Отличие от простого повторного запуска оптимизатора: здесь проверяется, может ли *метод* найти правду при известной правде, а не воспроизводимость одной подгонки.

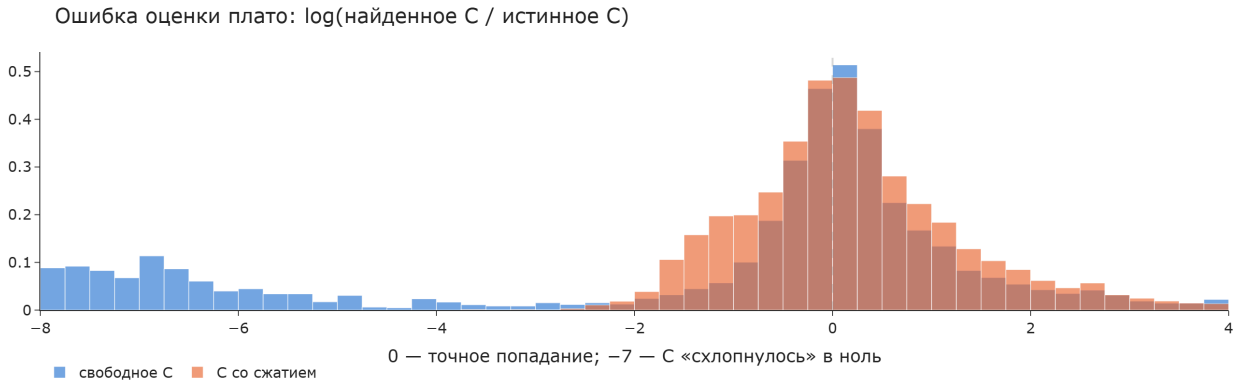



Рис. 12. Экран 6. Ошибка оценки плато $\log\left(\frac{\hat{C}}{C}\right)$ на искусственных играх, $L = 12$

**Как читать.** Две наложенные гистограммы: свободное $C$ (синее) и со сжатием (оранжевое). По оси x логарифм отношения найденного плато к истинному: 0 — точное попадание, $+1$ — завышение в $e \approx 2.7$ раза, $-7$ — оценка в тысячу раз меньше истины, то есть $C$ «схлопнулось» в ноль. Пунктир — точное попадание. У свободного $C$ два горба: основная масса около 0 и отдельный горб около $-7$ — у четверти искусственных игр (24%) оценка ушла на границу при истинном плато порядка единиц. Это и есть неидентифицируемость в картинке. У сжатия горба нет совсем: 0% на границе, разброс умеренный (примерно от $\div 3$ до $\times 6{,}5$). Под графиком — доля «схлопнувшихся» оценок. При $L = 26$ провал свободного $C$ остаётся у 18%.

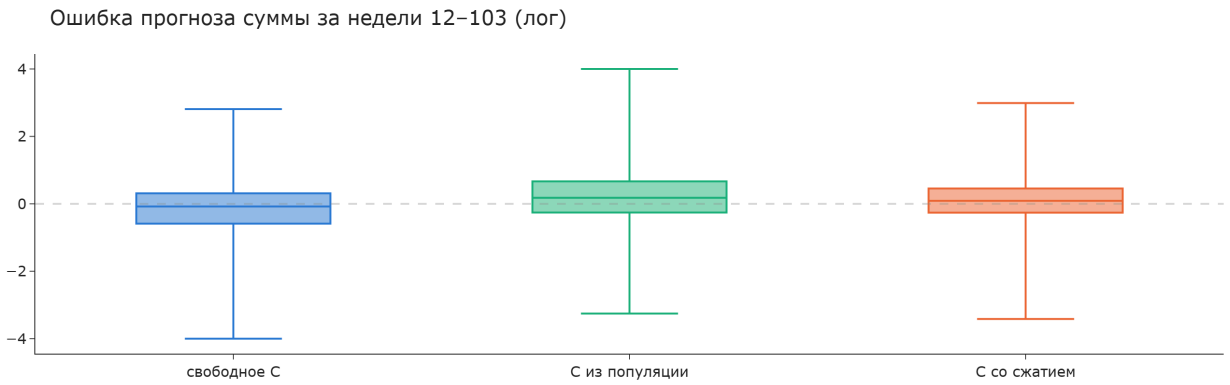



Рис. 13. Экран 6. Ошибка прогноза суммы за недели 12–103 на искусственных играх

**Как читать.** «Ящики с усами» ошибки $\log\left(\frac{\text{прогноз суммы}}{\text{истинная сумма}}\right)$ для трёх способов. Линия в ящике — медиана, ящик — от 25-го до 75-го процентиля, усы — основной разброс; выбросы обрезаны на ±4. Пунктир — ноль. Популяционное $C$ смещено вверх (медиана +0,18): медиана отношения в популяции не равна плато конкретной игры. Сжатие — самый узкий ящик около нуля. Под графиком средний модуль ошибки: сжатие 0,454 против 0,618 у свободного и 0,575 у популяционного. Тот же порядок, что на реальных играх, значит выигрыш сжатия — свойство оценивания, а не случайность данных.

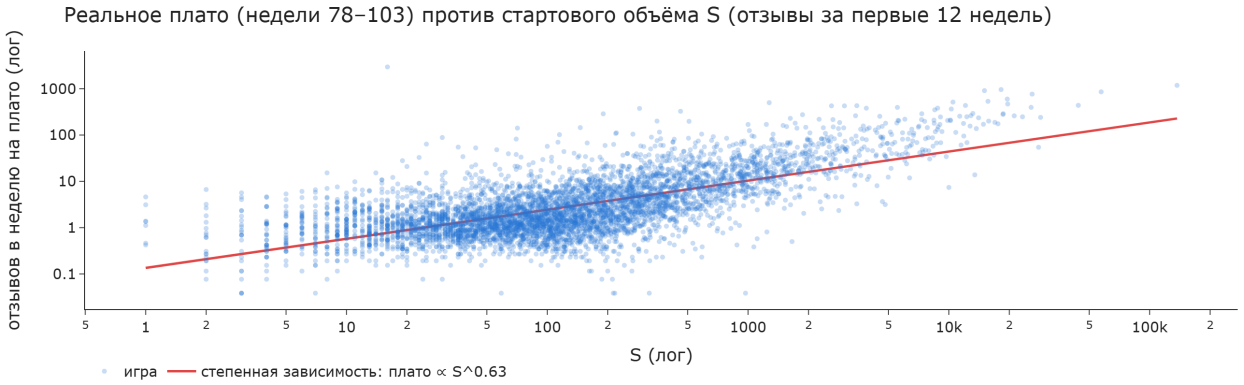



Рис. 14. Экран 6. Реальное плато против стартового объёма $S$, $L = 12$

**Как читать.** Каждая точка — реальная игра: по оси x сумма первых 12 недель $S$, по оси y средний уровень недель 78–103; обе оси логарифмические, поэтому степенная зависимость выглядит прямой, а её наклон — показатель степени. Красная прямая — подгонка $\ln(\text{плато})$ по $\ln S$, её наклон 0,63. Вертикальные «столбики» точек слева — малые целые $S$. Разброс вокруг прямой большой (порядок величины в обе стороны): размер старта определяет плато лишь в среднем.

**Почему на рисунке 0,63, а в регрессии 0,55.** Это две разные подгонки. Линия на рисунке — простая зависимость без жанра по всем играм сразу. Регрессия финальной модели оценивается по четырём фолдам, с поправкой на жанр, и её наклон $\beta_1 = -0.45$ относится к $\ln\left(\frac{\text{плато}}{S}\right)$, то есть показатель $1 + \beta_1 = 0.55$. Часть связи «размер — плато» объясняется жанром (у крупных игр одни жанры чаще других), поэтому с жанром показатель меньше. В анализе чувствительности (раздел 13) показатель от 0,4 до 0,6. Говорить «плато растёт примерно как $S^{0.55}$, от 0,4 до 0,6 в зависимости от выборки».

# 13 Устойчивость выводов

> **Теория 28. Анализ чувствительности**
>
> Вывод, который держится только при одном пороге отбора, ненадёжен: возможно, порог подобран под результат. **Анализ чувствительности** — повтор главного расчёта при других разумных решениях и проверка, что выводы не меняются. Здесь пять прогонов прогноза при $L = 12$: основной вариант, порог 100 отзывов (7537 игр, ряды пересобраны), не меньше 500 отзывов в окне (2156 игр), окно 78 недель (5687 игр), другое случайное разбиение на фолды.

Результат: ранжирование «смесь < финальная < шаблон ≈ сжатие» и знаки всех парных разностей сохраняются во всех пяти вариантах, интервалы не включают ноль. Конформная калибровка даёт 0,92 / 0,90 / 0,89 везде. Показатель плато от 0,39 до 0,61 (на крупных играх зависимость от размера сильнее). К разбиению на фолды чувствительность нулевая. Графика у этого шага нет; таблица в выводах приложения (раскрывающийся блок) и в журнале, п. 6.9.

После этого шага автор решил, что работе нужна не стопка листов, а интерактивный показ. Так появилось приложение (Streamlit и Plotly): экраны идут в порядке рассказа, у каждой модели свой постоянный цвет на всех экранах, экраны 2 и 5 считают имитации и прогноз выбранной игры на лету.

# 14 Толчки внутри прогноза

## 14.1 Вопрос

Финальная модель калибруется «слепым» конформным растяжением. Толчки — механистическая альтернатива: может, коридоры узки из-за редких скачков, и их надо моделировать явно?

**Теория 29. Толчки как популяционная величина**

По 12 неделям частоту толчков одной игры не оценить. Поэтому правило берётся из популяции. Каждая игра подгоняется по всем 104 неделям (степенной закон плюс плато на реальном уровне), и неделя-толчок размечается по правилу раздела 5. По играм других фолдов считаются вероятность толчка $p_b$ на каждом горизонте и логнормальное распределение *относительного* размера $Z = \frac{y-\mu}{\mu}$. В прогнозе

$$y_t \sim \mathrm{NB}(\mu_t(1 + B_t Z_t), r), \quad B_t \sim \mathrm{Bernoulli}(p_b), \quad \ln Z_t \sim \mathcal{N}(m, s^2).$$

Относительный размер — чтобы правило годилось и малым, и крупным играм.

Толчков 1% игро-недель, у 35% игр их нет, медианный скачок ×6,7. Добавленные в финальную модель (`reg_shock`), они почти ничего не меняют: покрытие +0,01, недельный CRPS −0,0004, калиброванная версия неотличима от конформной.

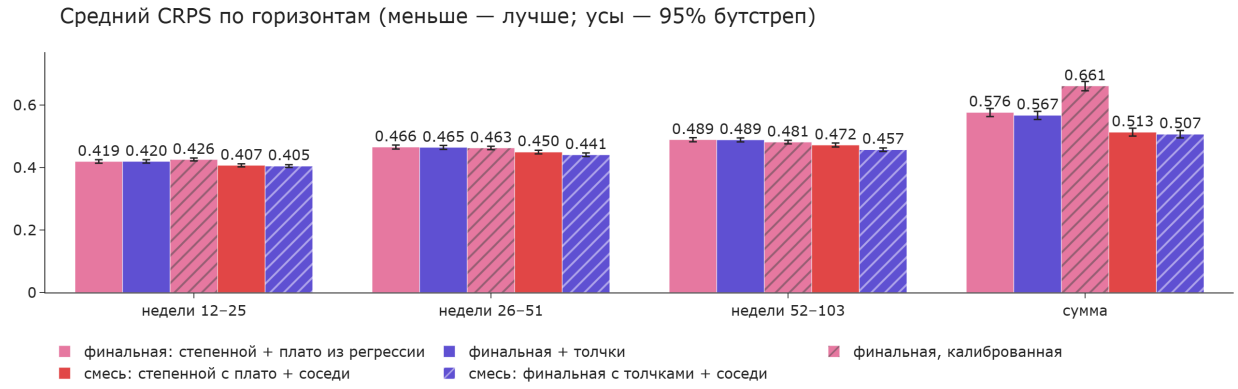



Рис. 15. Экран 9. Средний CRPS моделей с толчками и без, $L = 12$

**Как читать.** Как рисунок экрана 7: группы — горизонты и сумма, столбцы — модели, усы — 95% бутстреп. Модели: финальная, финальная с толчками (фиолетовая), калиброванная (штриховка), смесь и смесь с толчками (штриховка). Столбцы «с толчками» и «без» почти равны: толчки не дают выигрыша по точности. По сумме видно, что калиброванная хуже — как и раньше.

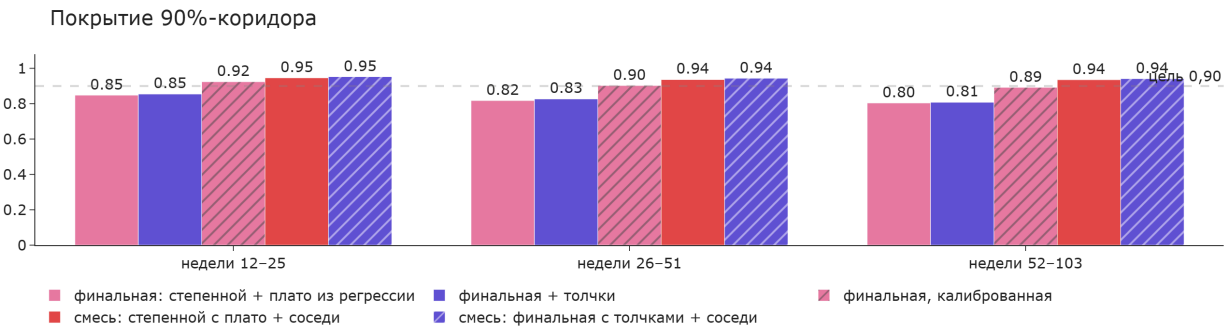



Рис. 16. Экран 9. Покрытие 90%-коридора моделей с толчками и без

**Как читать.** Доля недель, где факт в коридоре; пунктир — цель 0,90. Финальная с толчками лишь на 0,01 выше финальной без толчков и далеко не дотягивает до цели; калиброванная на цели. Под графиком таблица диагностики: какая доля недель — промахи коридора вверх и вниз и какая часть промахов вверх приходится на недели-толчки. Промахи вверх у финальной модели — 13% недель, из них только 8% на неделях-толчках (при 1% таких недель вообще), промахи вниз на толчках — 0%. CRPS на неделях-толчках 1,79 против 0,46 на остальных.

**Вывод.** Толчки реальны и дороги, но редки. Промахи коридора — в основном ошибки уровня плато, а не скачки; толчок с вероятностью 1% в 90%-коридор по построению не входит. Поэтому коридоры растягиваются конформным множителем, а толчки в финальную модель не добавляются.

# 15 Внешняя проверка на najzeko

## 15.1 Постановка

Все предыдущие проверки — на играх одного набора. Внешняя проверка: применить модель к другому набору, **ничего не переобучая**. В najzeko по тем же правилам осталось 178 игр, 166 из них есть в основной группе Anton.

Сначала сверка рядов на общих играх: Anton содержит медианно 0,51 отзывов najzeko (10–90%: 0,34–0,76), доля одинакова во все возрасты игры (0,50–0,52 по горизонтам) и почти одинакова по годам (0,40–0,48); первая неделя совпадает у всех; Спирмен недельных счётчиков 0,95. То есть **Anton — примерно случайная половина тех же отзывов**.

Прогноз: игры najzeko — отдельный «фолд»; шаблоны, соседи, регрессия плато, $r$ и конформные множители для них считаются только по играм Anton, из которых убраны все игры najzeko.

> **Теория 30. Биномиальное прореживание**
>
> Если из полного потока отзывов каждый независимо попадает в набор с вероятностью $q$, то недельный счётчик набора $Y' \sim \mathrm{Bin}(Y, q)$, и $EY' = qEY$. **Доли** (форма ряда, $\tau_h$ шаблона и соседей) от $q$ не зависят: числитель и знаменатель умножаются на $q$. А **уровни** умножаются на $q$.
>
> Отсюда предсказание для финальной модели. Её плато $C = \hat{\kappa} S \propto S^{0.55}$. Если набор вдвое полнее ($S \to 2S$), правило даёт плато выше в $2^{0.55} \approx 1.46$ раза, а настоящее плато выше в 2 раза. Модель занизит плато примерно в $\frac{2}{1.46} \approx 1.37$ раза. Правило «плато $\propto S^{0.55}$» **не инвариантно к охвату набора**, а шаблон и соседи инвариантны.
>
> Проверка этого объяснения: проредить najzeko до половины ($q = 0.5$, каждый отзыв оставлен с вероятностью 0,5) и повторить прогноз. Если разрыв в основном из-за охвата, результат вернётся к уровню тех же игр внутри Anton.

## 15.2 Результат

- Смесь и на чужом наборе лучшая: CRPS суммы на 0,138 ниже шаблона [−0,198; −0,078], покрытие 0,82–0,91.
- Финальная формула занижает плато: покрытие на неделях 52–103 0,42 против 0,67 у крупных игр Anton.
- После прореживания до половины покрытие 0,49 — почти как у тех же игр внутри Anton (0,51). Объяснение охватом подтверждено. Оставшийся разрыв с «Anton ≥ 500» — свойство самих игр: это самые популярные игры, и внутри Anton они тоже даются хуже среднего.

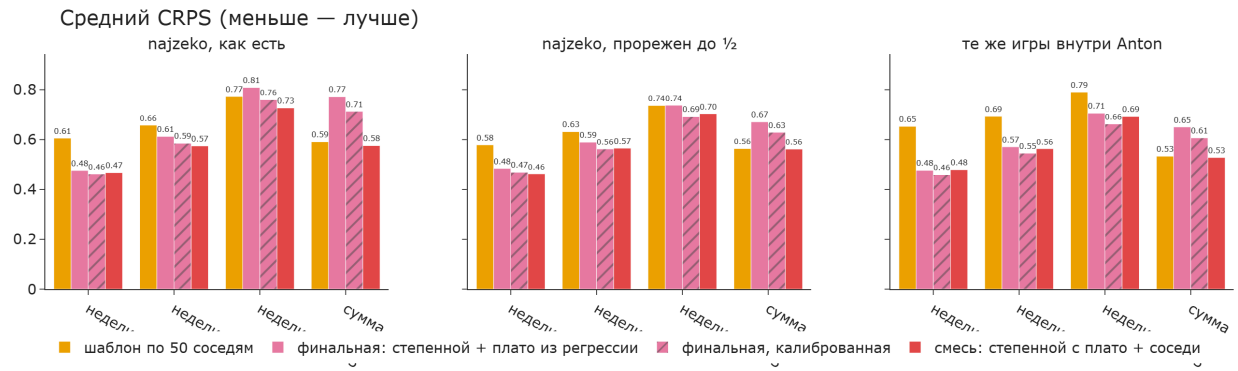



Рис. 17. Экран 10. Средний CRPS на внешнем наборе, $L = 12$

**Как читать.** Три панели с общей осью y: najzeko как есть, najzeko, прореженный до половины, и те же игры внутри прогона Anton. В каждой — горизонты и сумма, столбцы — шаблон по соседям, финальная, калиброванная (штриховка) и смесь. Смотреть надо на сходство панелей: средняя и правая почти одинаковы, левая хуже на дальних горизонтах у финальной модели (занижение плато). Смесь ниже или наравне со всеми во всех трёх.

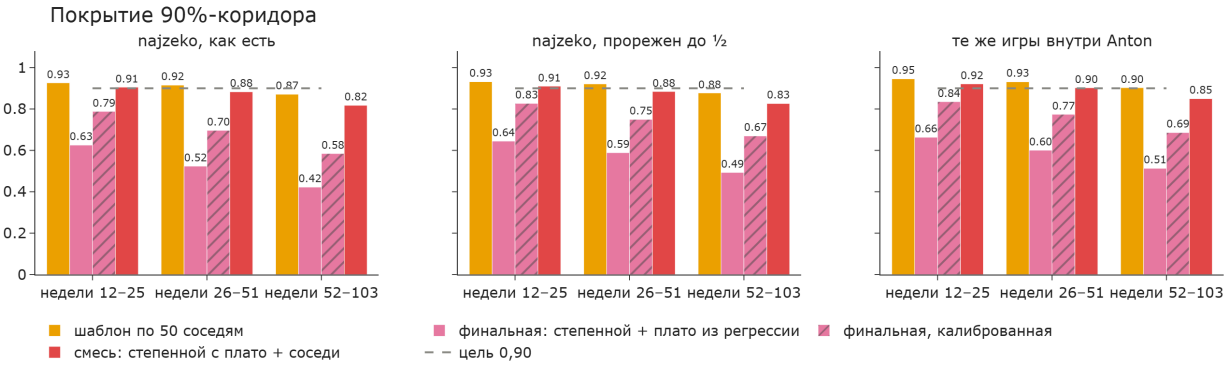



Рис. 18. Экран 10. Покрытие 90%-коридора на внешнем наборе

**Как читать.** Те же три панели; пунктир — цель 0,90. Шаблон по соседям и смесь около цели во всех трёх панелях: долевые части модели переносятся. Финальная модель (розовая) и калиброванная (штриховка) теряют покрытие к дальнему горизонту, сильнее всего в левой панели (0,42 и 0,58): масштабная часть модели не переносится на набор с другим охватом. Прореживание (средняя панель) возвращает их почти к правой.

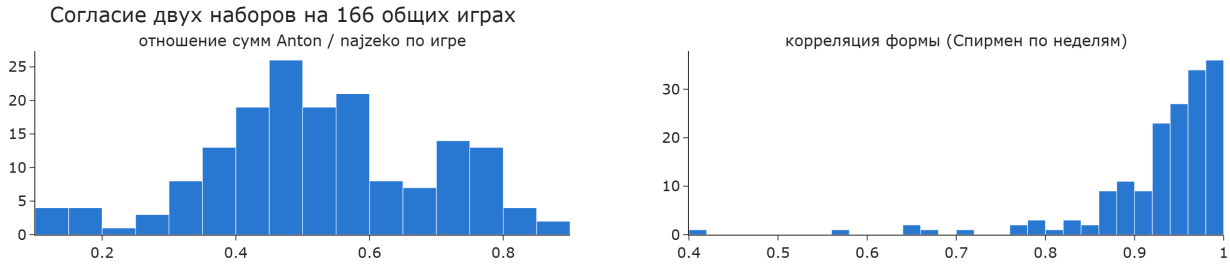



Рис. 19. Экран 10. Согласие двух наборов на 166 общих играх

**Как читать.** Левая гистограмма — отношение суммы отзывов игры в Anton к сумме в najzeko; пик около 0,5 — Anton держит половину отзывов. Правая — Спирмен недельных счётчиков одной игры в двух наборах; почти все значения выше 0,9 — форма одинакова. Вместе: это те же ряды в масштабе ½.

# 16 Параметры как факты об играх

## 16.1 Вопрос

Параметры финальной модели можно читать не только как средство прогноза, но и как описание игр: кто быстрее теряет аудиторию, у кого выше плато. Здесь впервые использована доля положительных отзывов (`n_positive`).

Для каждой из 5311 игр по полному окну:

- $\alpha$ — скорость спада (степенной закон с плато, зафиксированным на реальном уровне);
- **плато относительно типичного для размера** — реальное плато, делённое на сумму первых 12 недель и затем на то, что для такого старта типично (остаток регрессии $\ln\left(\frac{\text{плато}}{S_{12}}\right)$ по $\ln S_{12}$, в разах; 1 — как у типичной игры того же размера);
- **доля первых 4 недель** — насколько резкий старт;
- **доля положительных** в первые 12 недель (известна уже в момент прогноза) и её тренд (недели 4–11 минус 0–3).

> **Теория 31. Медиана с бутстреп-интервалом, ранговая корреляция, стандартизованные коэффициенты**
>
> **Медиана группы с бутстреп-интервалом**: 1000 раз берутся игры группы с возвращением, считается медиана; 2,5-й и 97,5-й процентили — 95%-интервал. Медиана, а не среднее, потому что $\alpha$ и плато имеют тяжёлые хвосты.
>
> **Сравнение по поправке на размер** нужно, потому что группы отличаются размером: бесплатные игры в среднем крупнее, а у крупных игр плато в долях ниже само по себе. Без поправки «у бесплатных низкое плато» могло бы значить просто «бесплатные крупнее».
>
> **Стандартизованный коэффициент** регрессии — $\beta_j \cdot \mathrm{sd}(x_j)$: на сколько меняется прогноз, когда признак меняется на одно своё стандартное отклонение. Позволяет сравнить вклад признаков в разных единицах (цена в долларах, доля, флаг).
>
> **Утечка через признак**: рейтинг игры в каталоге собран в 2022 году и включает отзывы за весь прогнозный период. В регрессии прогноза его использовать нельзя: он «знает будущее». Поэтому используется только доля положительных среди отзывов обучающих недель; с рейтингом каталога она коррелирует 0,75.
>
> Всё в этом разделе описательно: группы отличаются многим сразу (размер, год, аудитория), причинных утверждений нет.

## 16.2 Результат

- **Цена.** Бесплатные: плато 0,67 от типичного [0,63; 0,74] и самый резкий старт (0,26). До 4,99 $ — самый медленный спад ($\alpha$ 1,03). От 15 $ — самый быстрый спад ($\alpha$ 1,48), но плато выше типичного (1,12).
- **Год выхода.** До 2015 — плато 1,21, 2016–17 — 0,78, 2018–19 — 0,99. Возможен вклад роста аудитории Steam во второй год жизни старых игр; разделить нельзя.
- **Теги.** Выше плато у Atmospheric (1,21), Puzzle (1,14), Story Rich (1,12); ниже у Anime (0,76), RPG (0,82), Indie (0,90 против 1,11 у остальных).
- **Доля положительных** в первые 12 недель предвещает плато: верхняя четверть 1,25, нижняя 0,76; Спирмен с плато +0,17 [+0,14; +0,19]. Тренд доли слабее (+0,07).
- **Расширенная регрессия плато** (размер, первый тег, цена, бесплатность, год, доля положительных и её тренд, 15 тегов): разброс остатка 1,005 → 0,953. Финальная модель

с таким плато: CRPS суммы 0,577 → 0,552, разность −0,024 [−0,030; −0,018]. Улучшение небольшое, но устойчивое; в смесь не внедрялось.

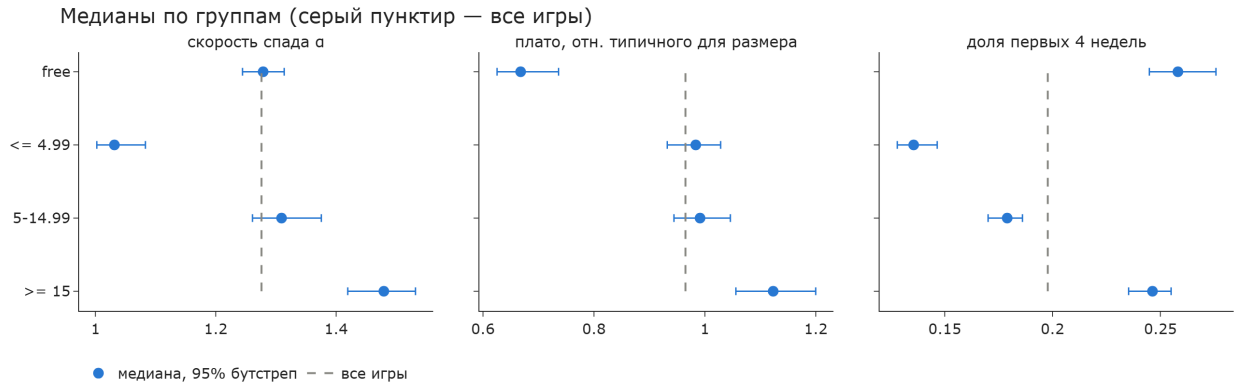



Рис. 20. Экран 11. Медианы параметров по группам, разрез «цена»

**Как читать.** Три панели: скорость спада $\alpha$, плато относительно типичного для размера, доля первых 4 недель. По оси y — группы выбранного разреза (на рисунке цена; в приложении ещё год, доля положительных и теги). Точка — медиана группы, усы — 95%-интервал бутстрепа. Серый пунктир — медиана по всем играм. Группа отличается от общей картины, если её усы не задевают пунктир. Например, бесплатные игры: $\alpha$ как у всех, плато заметно ниже, старт резче. В разрезе «теги» добавлены серые штрихи — медиана остальных игр без этого тега: сравнивать точку надо с её штрихом.

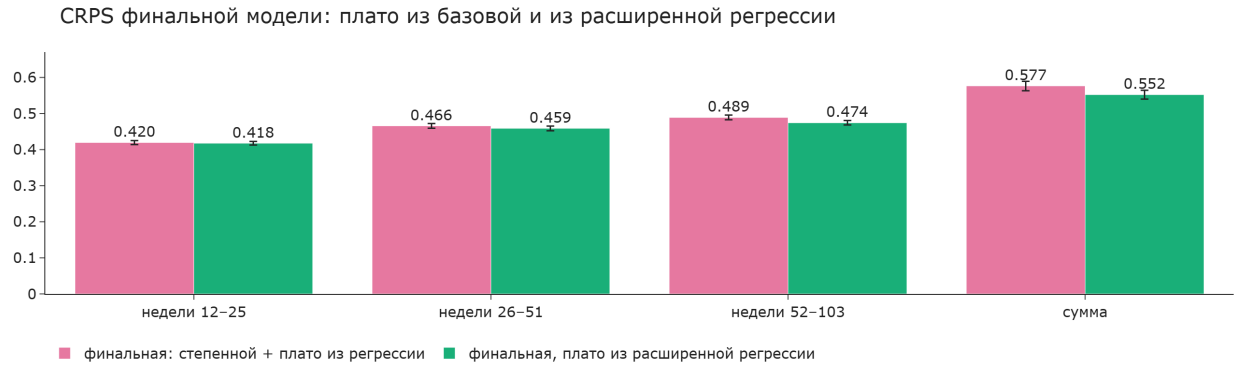



Рис. 21. Экран 11. CRPS финальной модели с базовой и расширенной регрессией плато, $L = 12$

**Как читать.** Два столбца на каждом горизонте: финальная модель с плато из базовой регрессии (размер и жанр, розовый) и из расширенной (с ценой, годом, долей положительных и тегами, зелёный). Усы — 95% бутстреп. Зелёный ниже на всех горизонтах; на ближнем разница почти незаметна (0,418 против 0,420), к дальним растёт. Значимость проверяется не по усам, а парной разностью на одних и тех же играх: по сумме −0,024 [−0,030; −0,018], по неделям −0,008 [−0,010; −0,006]. Признаки, известные на 12-й неделе, немного, но надёжно улучшают прогноз плато.

# 17 Итог

## 17.1 Что мы утверждаем

1. Жизнь игры по отзывам — быстрый спад и плато. Без плато любая кривая спада проигрывает наивному прогнозу.
2. Плато по коротким рядам не оценивается (показано имитацией с известной истиной); его надо брать из популяции. Оно растёт примерно как $S^{0.55}$.
3. Лучшие модели по правдоподобию (Хокс, толчки) не лучшие по имитации: модели надо сравнивать по тому, что они порождают.
4. Типы траекторий данные не поддерживают, кроме грубого деления на два.
5. Прогноз по 12 неделям: финальная формула лучше шаблона на всех горизонтах и после конформного множителя откалибрована; смесь с «памятью» о похожих играх лучше ещё на четверть.
6. Всё повторяется на числе игроков, а отзывы доказанно повторяют форму онлайна.
7. Толчки реальны, но редки (1% недель) и прогноз не улучшают: промахи коридора — ошибки уровня, не скачки.
8. На чужом наборе отзывов ранжирование и смесь переносятся; правило плато зависит от охвата набора.
9. Параметры описывают игры: бесплатные — резкий старт и низкое плато, дорогие — быстрый спад и высокое плато, положительные первые отзывы предвещают плато.

## 17.2 Где слабо (сказать самому)

- Отбор по популярности ($\geq$ 200 отзывов): выводы про игры с заметной аудиторией.
- Сравнение восьми моделей внутривыборочное; в прогнозе пороги и список моделей выбирались по тем же играм (небольшая утечка).
- На онлайне NB — рабочая модель разброса, коридоры там не откалиброваны (0,3–0,76).
- Жанр — только первый тег; у 20% игр плато не находится даже по 104 неделям.
- Внешний набор — 178 популярных игр с вдвое большим охватом: проверка переноса, а не повторение на такой же выборке.
- Причины всплесков (акции, обновления) в данных отсутствуют.

## 17.3 Вопросы, которые могут задать

**Где здесь имитационное моделирование?** В трёх местах: сравнение моделей по 200 сгенерированным рядам на игру (раздел 3), прогноз как распределение 200 продолжений (раздел 7), восстановление параметров, где модель — генератор с известной истиной (раздел 12).

**Почему не Пуассон?** Дисперсия реальных рядов в разы больше среднего; Пуассон — частный случай NB при $r \to \infty$, и данные его отвергают.

**Что такое CRPS простыми словами?** Среднее расстояние между предсказанным распределением и фактом; для точечного прогноза — модуль ошибки. Наказывает и за промах, и за лишнюю ширину.

**Почему CRPS на логарифмической шкале?** Чтобы игра с 10 тысячами отзывов не перевесила тысячу игр с сотней, и ошибка «вдвое» значила одно и то же.

**Что такое фолд?** Одна из пяти частей игр; всё популяционное считается по четырём и применяется к пятой, поэтому проверяемая игра никогда не участвует в своей подсказке.

**Почему смесь 50/50?** Веса заранее заданы, чтобы не подгонять их на тех же играх. И по выпуклости CRPS смесь не хуже среднего своих частей.

**Почему финальная модель — не смесь?** Решение автора: финальная модель должна записываться одной формулой и объясняться одной строкой. Смесь — лучший достижимый прогноз для сравнения.

**Почему плато $\propto S^{0.55}$, а не $\propto S$?** Крупные игры удерживают меньшую долю старта: старт раздут рекламой и хайпом. Показатель 0,4–0,6 в зависимости от выборки.

**Почему не Хокс, раз он лучший по AIC?** AIC оценивает объяснение виденного ряда с подсказкой его прошлого; в свободной имитации эхо накапливает случайность, коридоры расползаются.

**Можно ли по отзывам узнать число игроков?** Форму — да (корреляция изменений 0,42 против 0,09 у контроля), масштаб — нет (разброс в 27 раз между играми).

**Почему конформный множитель, а не толчки?** Толчки проверены (экран 9): промахи коридора на 92% не на неделях-толчках, толчки покрытие не чинят. Множитель чинит покрытие по построению.